Métodos Cuantitativos

Clase 04 - Estadística descriptiva

Unidad I: Estadística y Probabilidades con Python

Repaso estadística

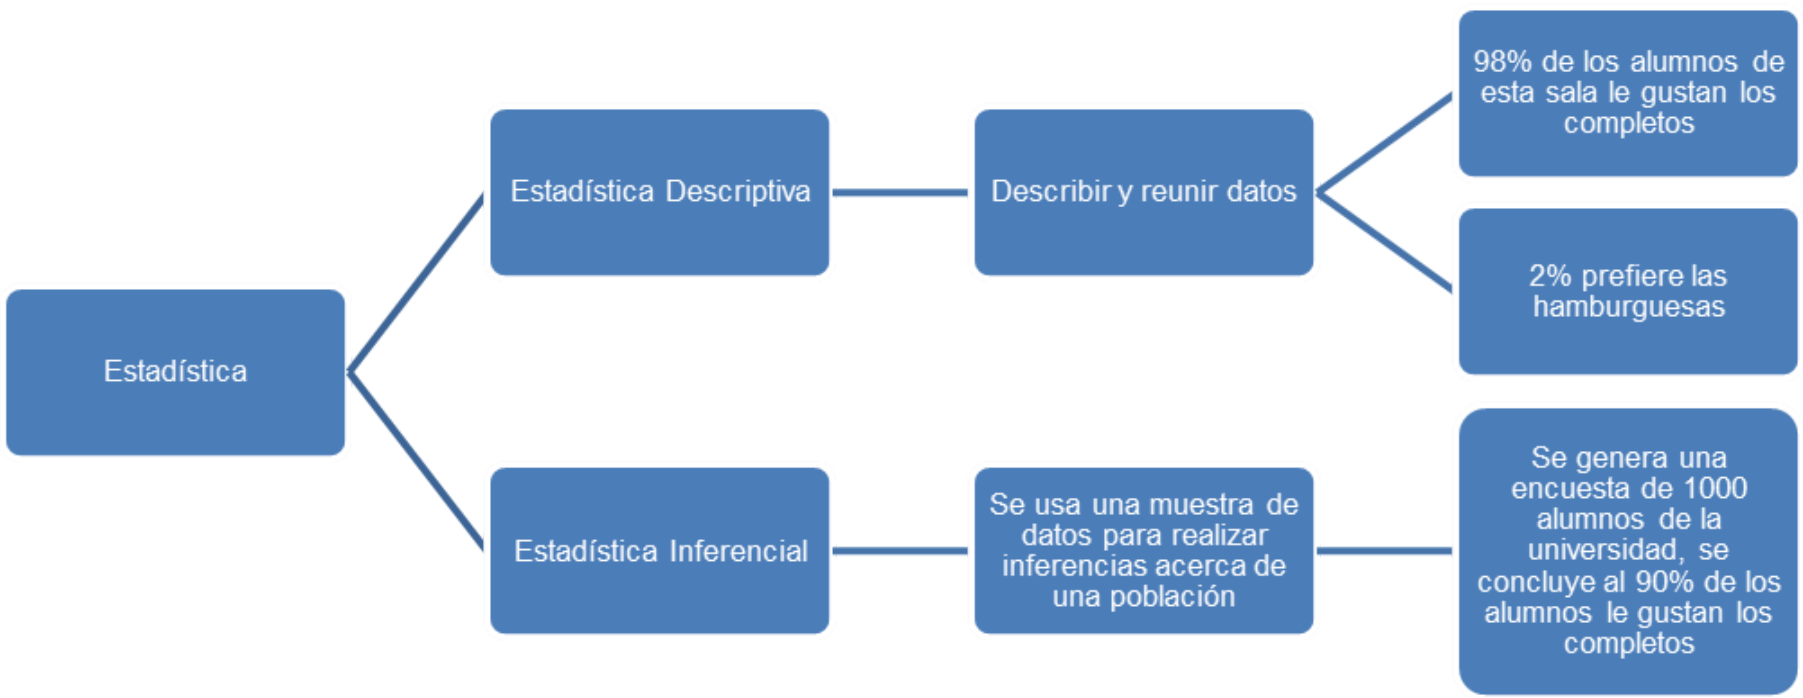

Tipos de datos numéricos

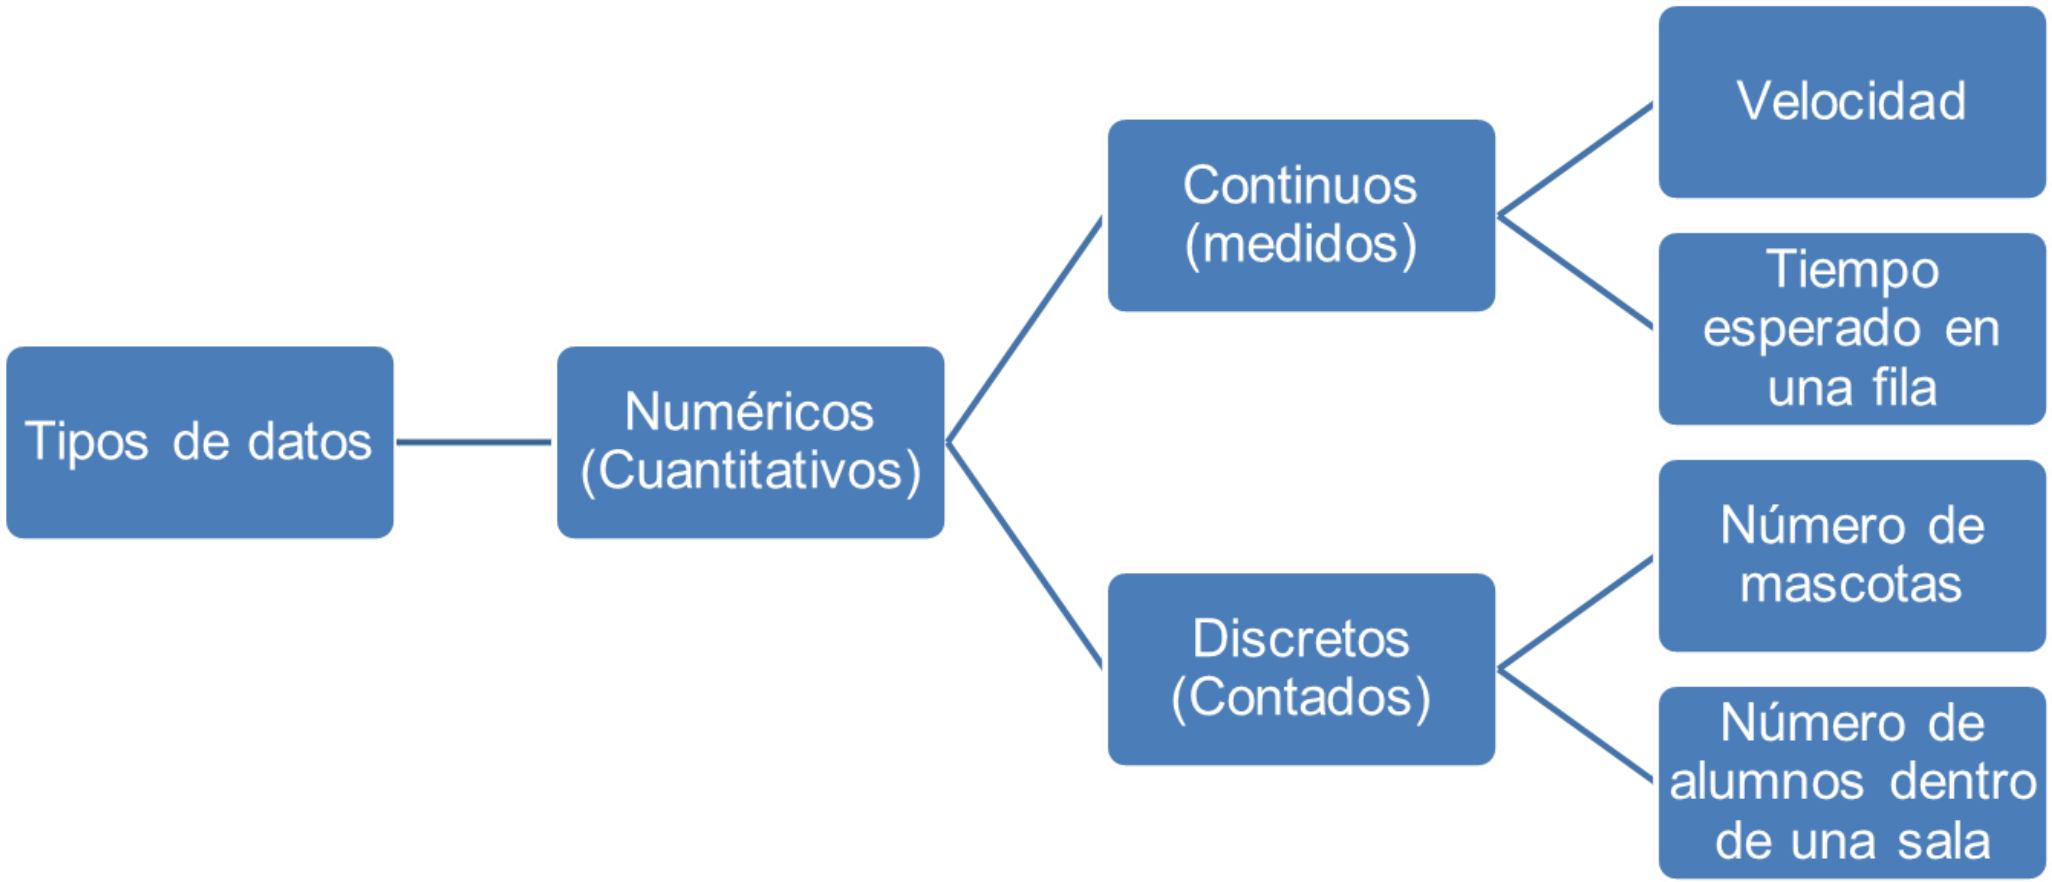

Tipos de datos categóricos

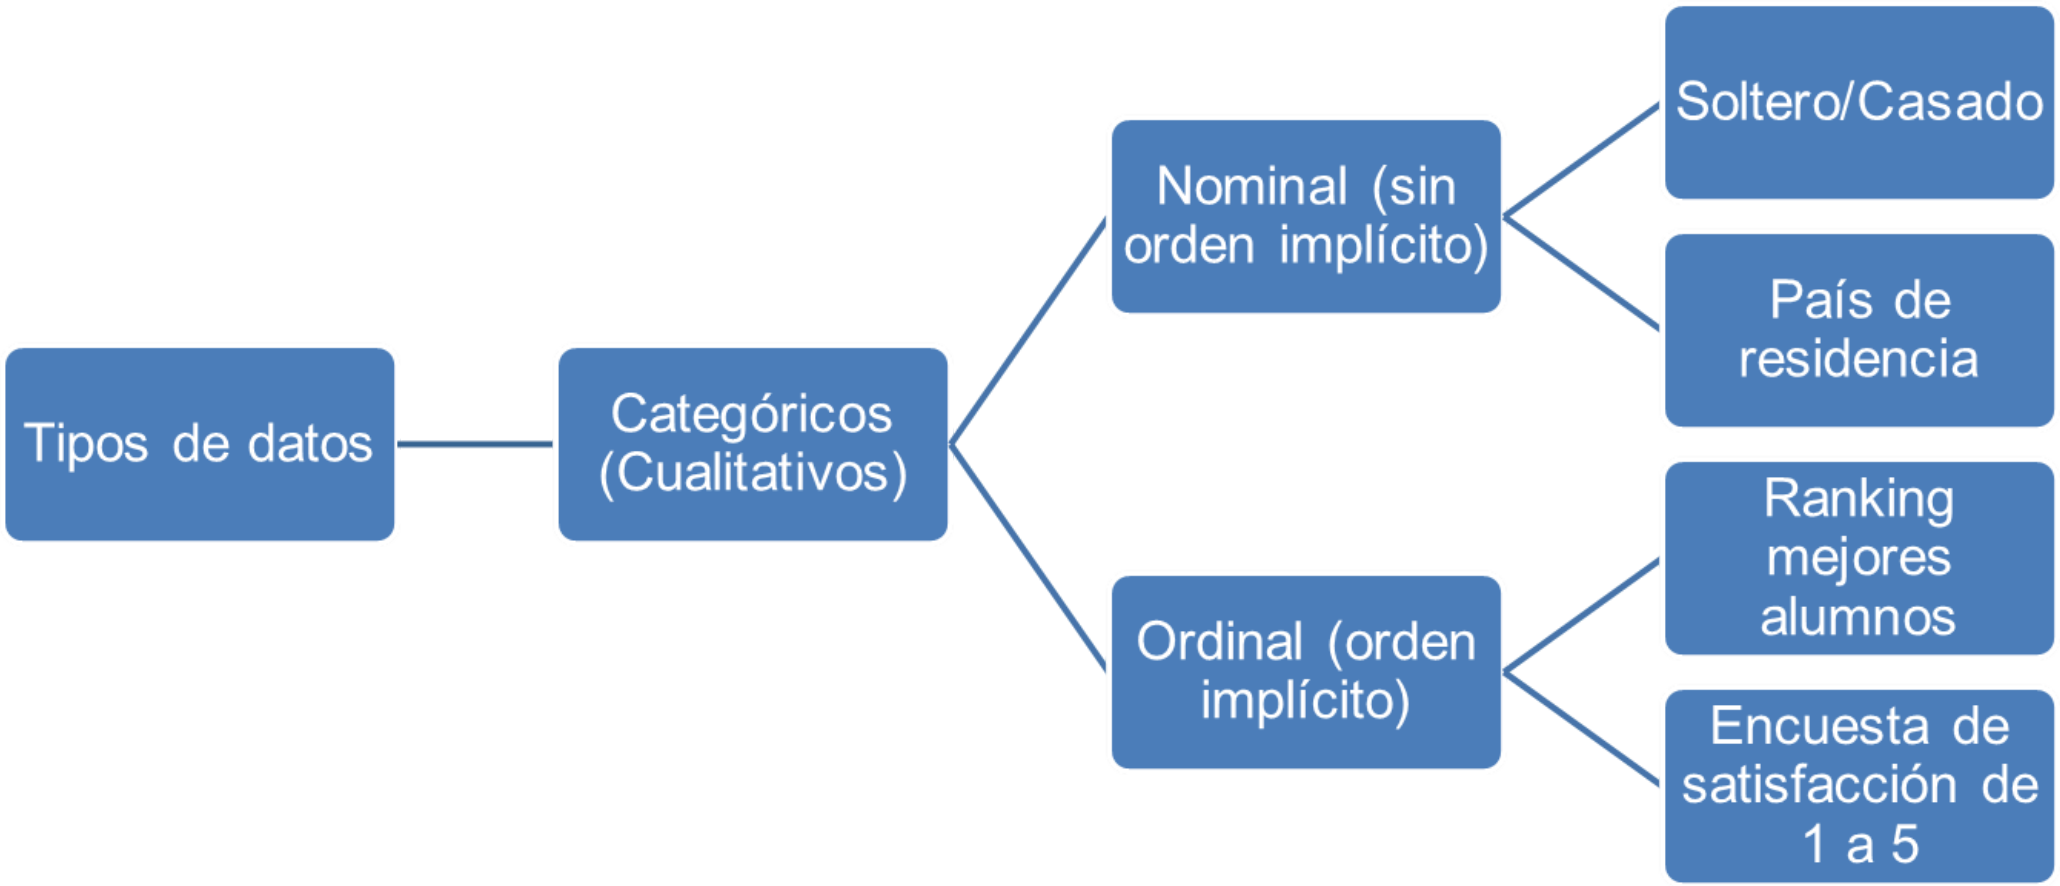

¿Qué veremos hoy?

- **Tipos de datos**
- Medidas de tendencia central
- Medidas de dispersión
- Cuartiles, percentiles e IQR
- Outliers y resumen en Pandas

¿Por qué es importante el tipo de dato?

- Conocer y usar el correcto tipo de dato es importante porque dictará qué tipo de resumen estadístico y visualización es coherente para nuestros datos.
- Ciertas operaciones matemáticas y algoritmos solo entregarán resultados correctos para ciertos tipos de datos. Por ejemplo, el algoritmo k-medias funciona con variables numéricas y una medida de distancia apropiada.

¿Por qué es importante el tipo de dato?

	age	sex
374	3	female
840	20	male
591	52	female
62	45	male
389	17	female
715	19	male

	age	sex
374	3	1
840	20	0
591	52	1

¿Por qué es importante el tipo de dato?

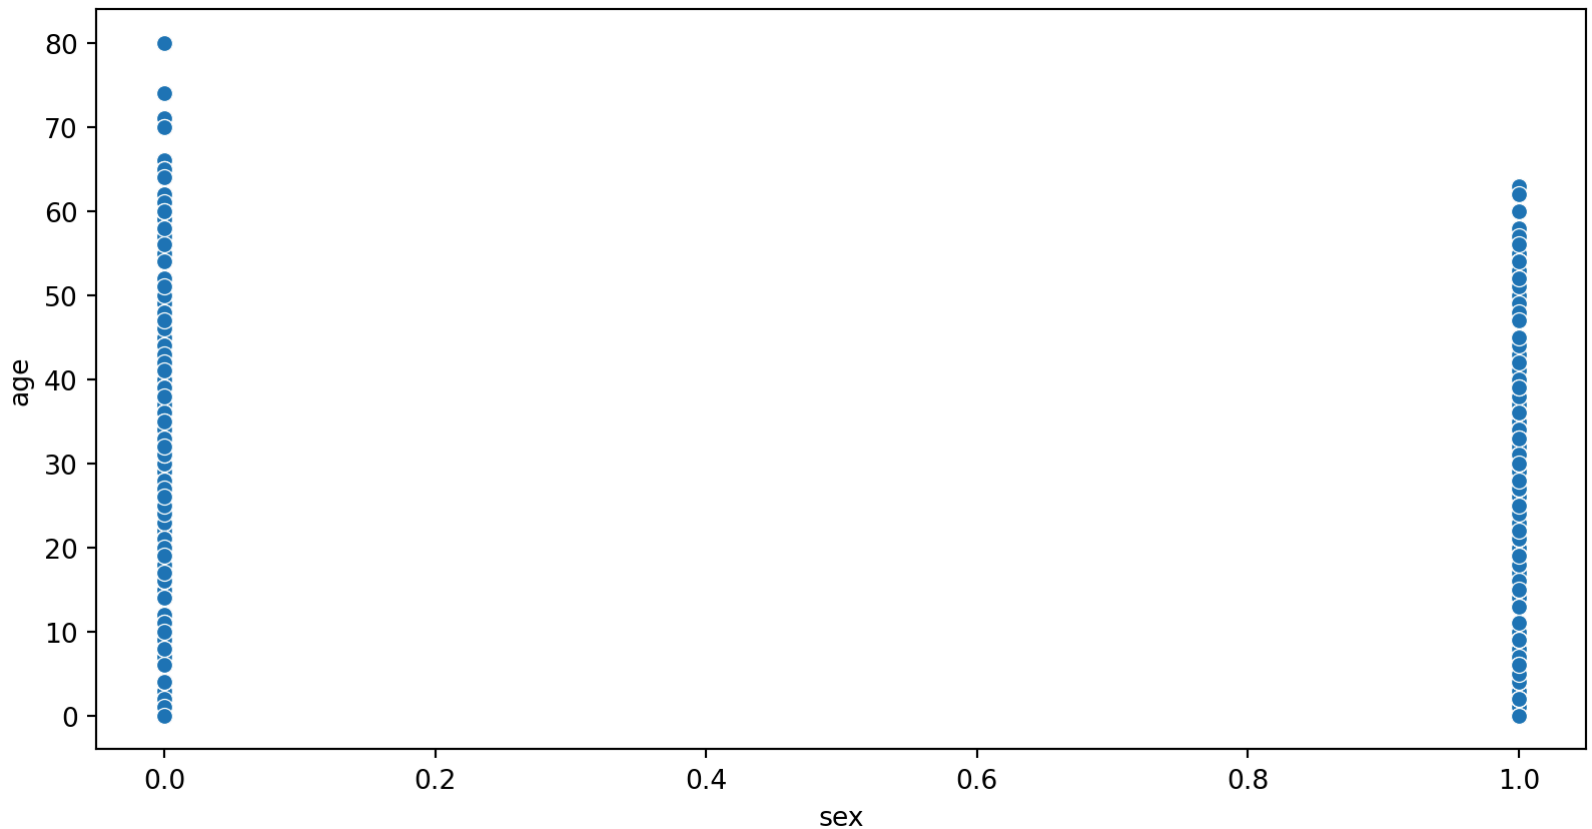

¿Por qué es importante el tipo de dato?

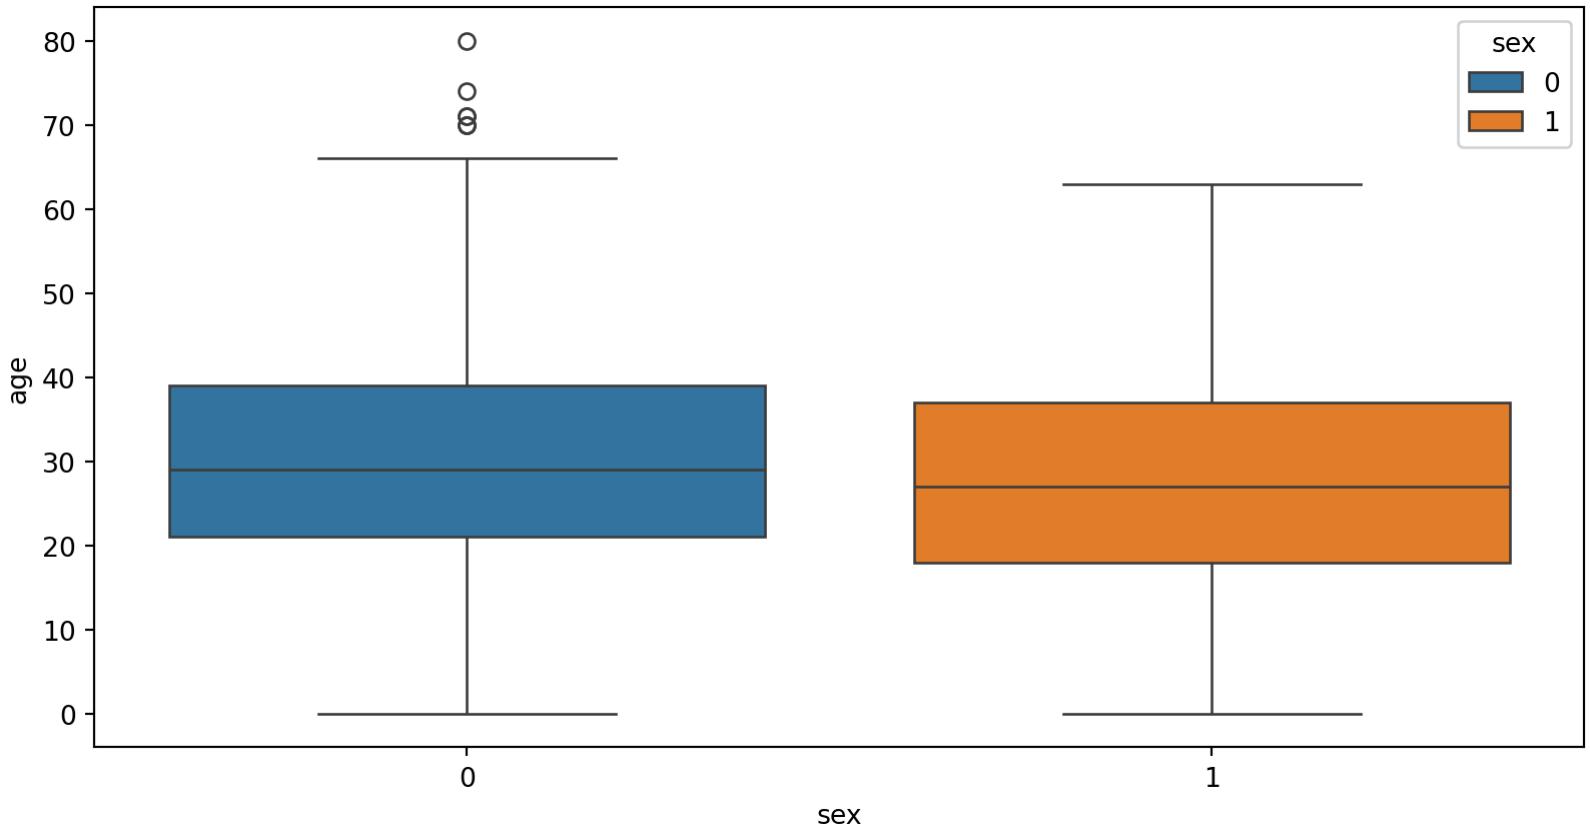

¿Qué veremos hoy?

- Tipos de datos
- **Medidas de tendencia central**
- Medidas de dispersión
- Cuartiles, percentiles e IQR
- Outliers y resumen en Pandas

Medidas de tendencia central

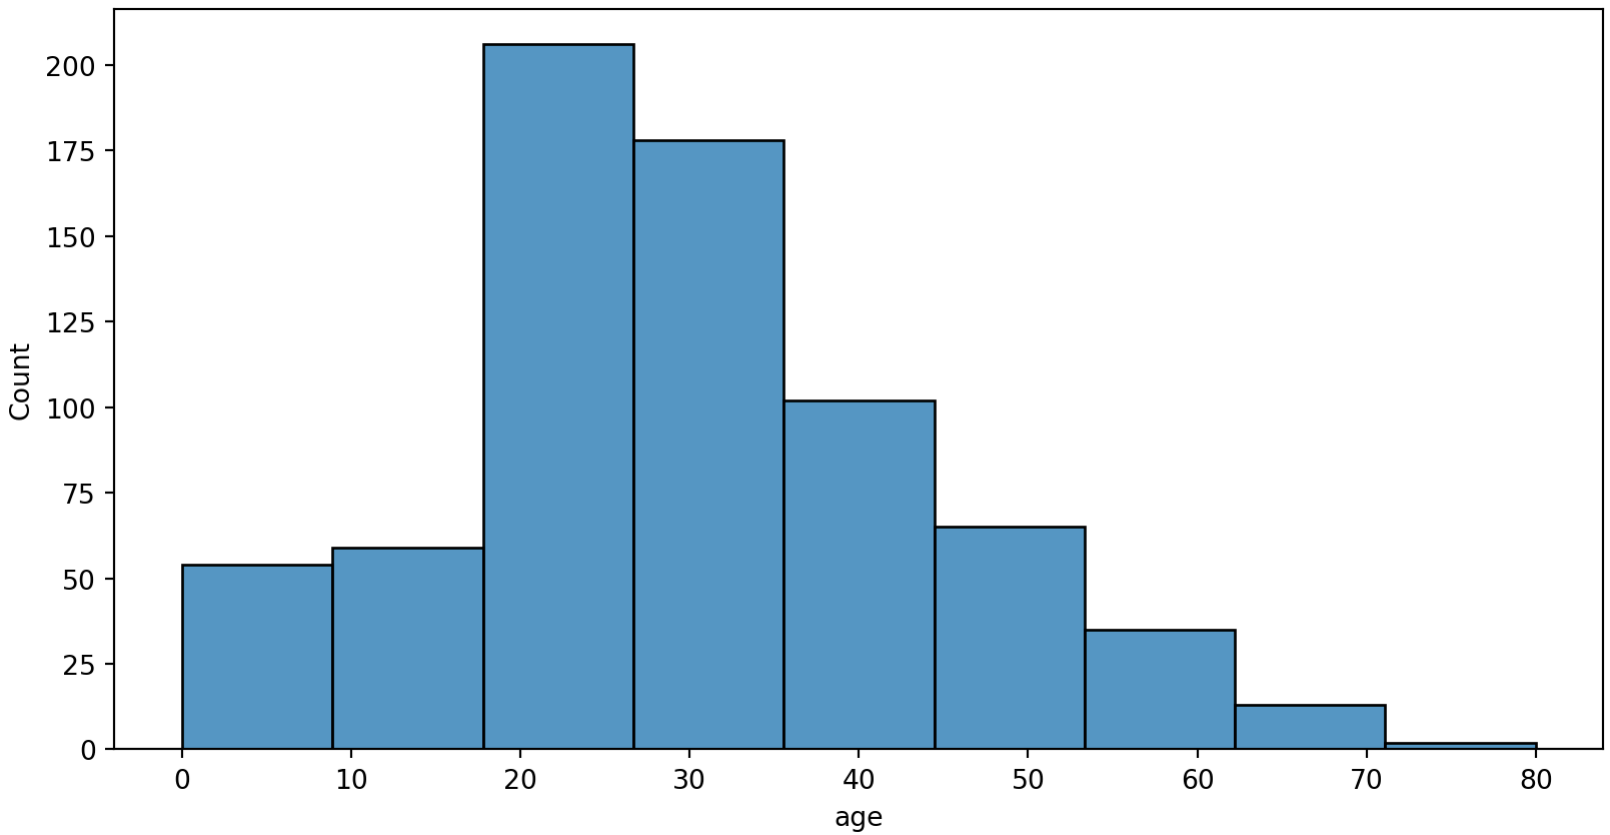

¿Cuál es la edad promedio?

¿cuál es la edad central?

Media

	sex	age
0	male	22
1	female	38
2	female	26
...	...	...
887	female	19
889	male	26
890	male	32

714 rows × 2 columns

$$\frac{22+38+26+35+...+27+19+26+32}{714} = 29.68$$

Mediana

	sex	age
644	female	0
78	male	0
305	male	0
…	…	…
96	male	71
851	male	74
630	male	80

714 rows × 2 columns

0, 0, 0, 0, …, **28**, 71, 71, 74, 80

Moda

```
age
24    31
22    27
28    27
      ..
80     1
12     1
74     1
Name: count, Length: 71, dtype: int64
```

La **edad más frecuente** entre los pasajeros del Titanic es de **24 años de edad**, compuesta por 31 pasajeros.

¿Cómo calcularlo en Python?

```python
import statistics

statistics.mode(titanic["age"])
```

```
24
```

Moda

```
0        male
1      female
2      female
        ...
887    female
889      male
890      male
Name: sex, Length: 714, dtype: object
```

```
sex
male      453
female    261
Name: count, dtype: int64
```

El **sexo más frecuente** entre los pasajeros del Titanic es **male**, compuesto por 453 pasajeros.

¿Cómo calcularlo en Python?

¿Qué medida utilizar?

La medida central a utilizar dependerá de la **distribución** que tengan nuestros datos, dado que la **media** es más sensible a los valores extremos, es mejor en escenarios que se cuente con **datos más simétricos**.

¿Qué medida utilizar?

Cuando los datos son **asimétricos**, la **mediana** se destaca como un estadístico robusto, ya que permanece constante incluso cuando los extremos de los datos están alterados.

¿Qué medida utilizar?

- Si **media=moda=mediana**, la distribución es simétrica
- Si **media > mediana**, la distribución es asimétrica con cola a la derecha (sesgada a la derecha)
- Si **media < mediana**, la distribución es asimétrica con cola a la izquierda (sesgada a la izquierda)

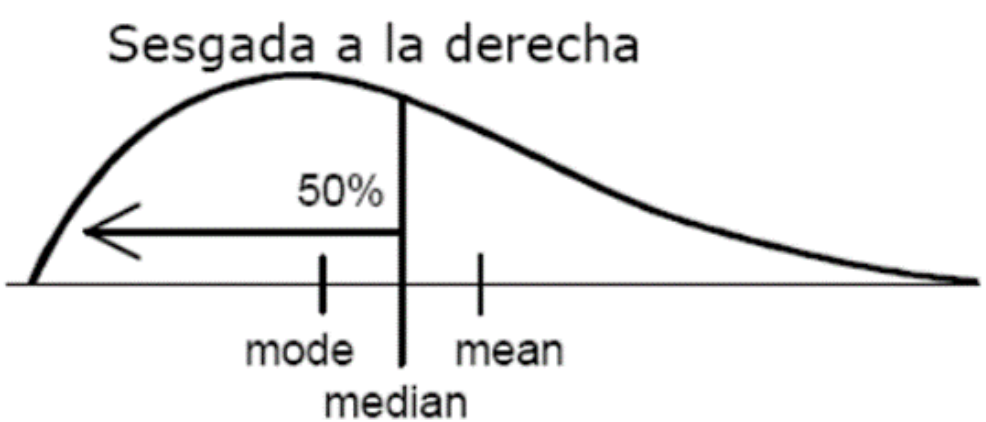

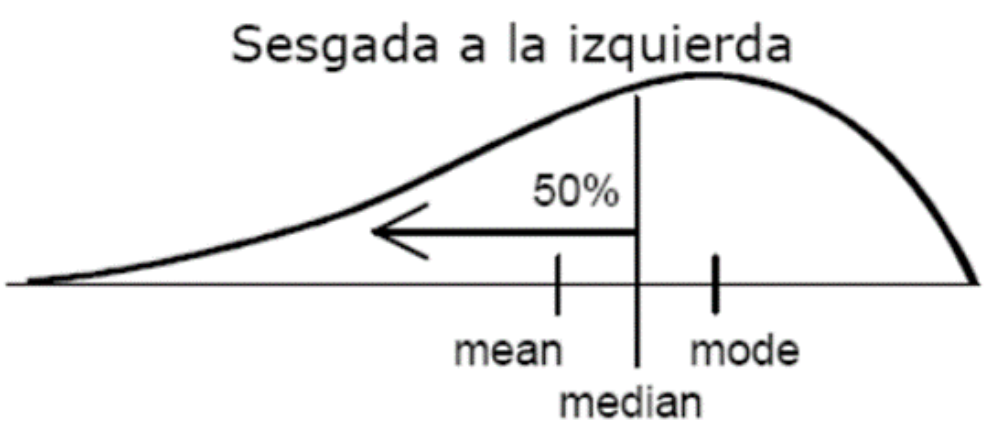

¿Qué veremos hoy?

- Tipos de datos
- Medidas de tendencia central
- **Medidas de dispersión**
- Cuartiles, percentiles e IQR
- Outliers y resumen en Pandas

Medidas de dispersión

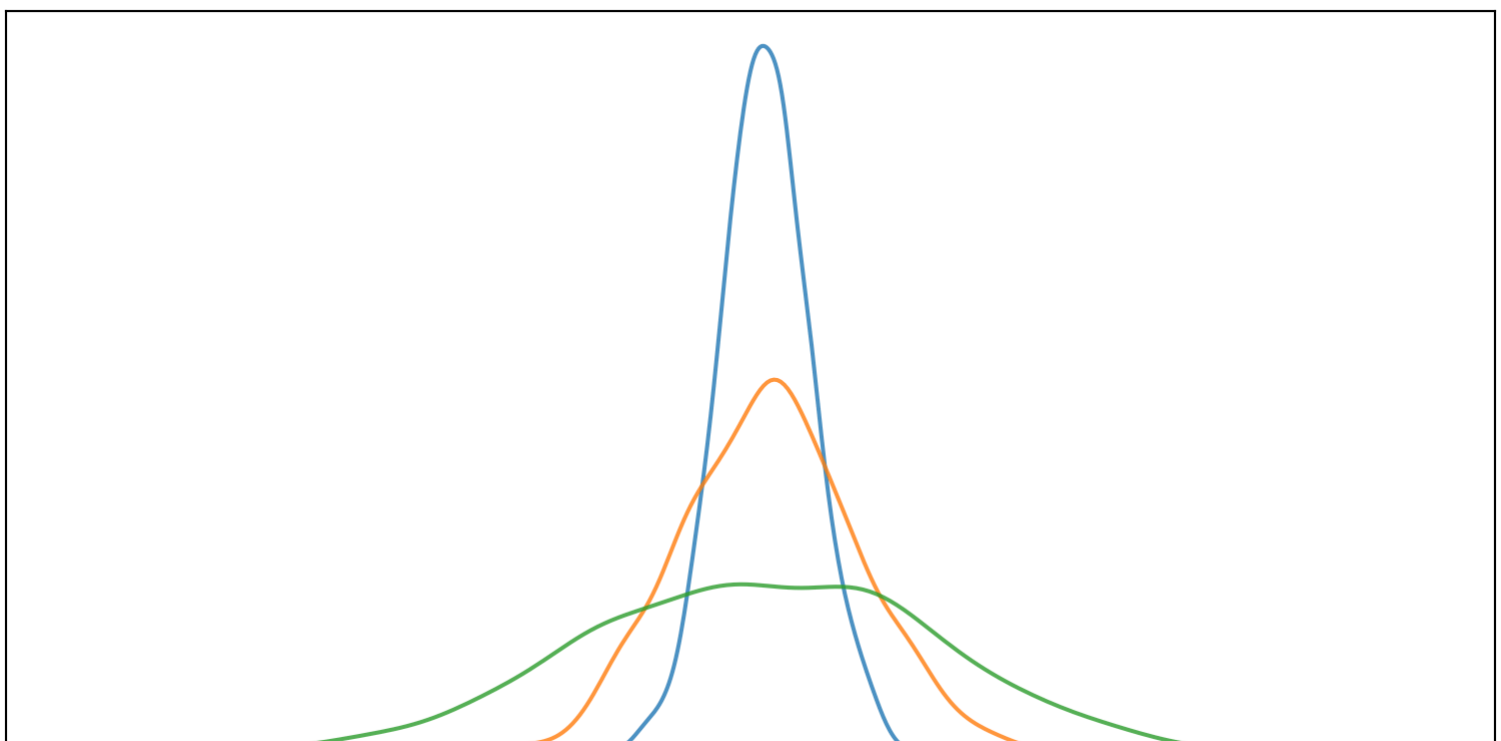

Varianza

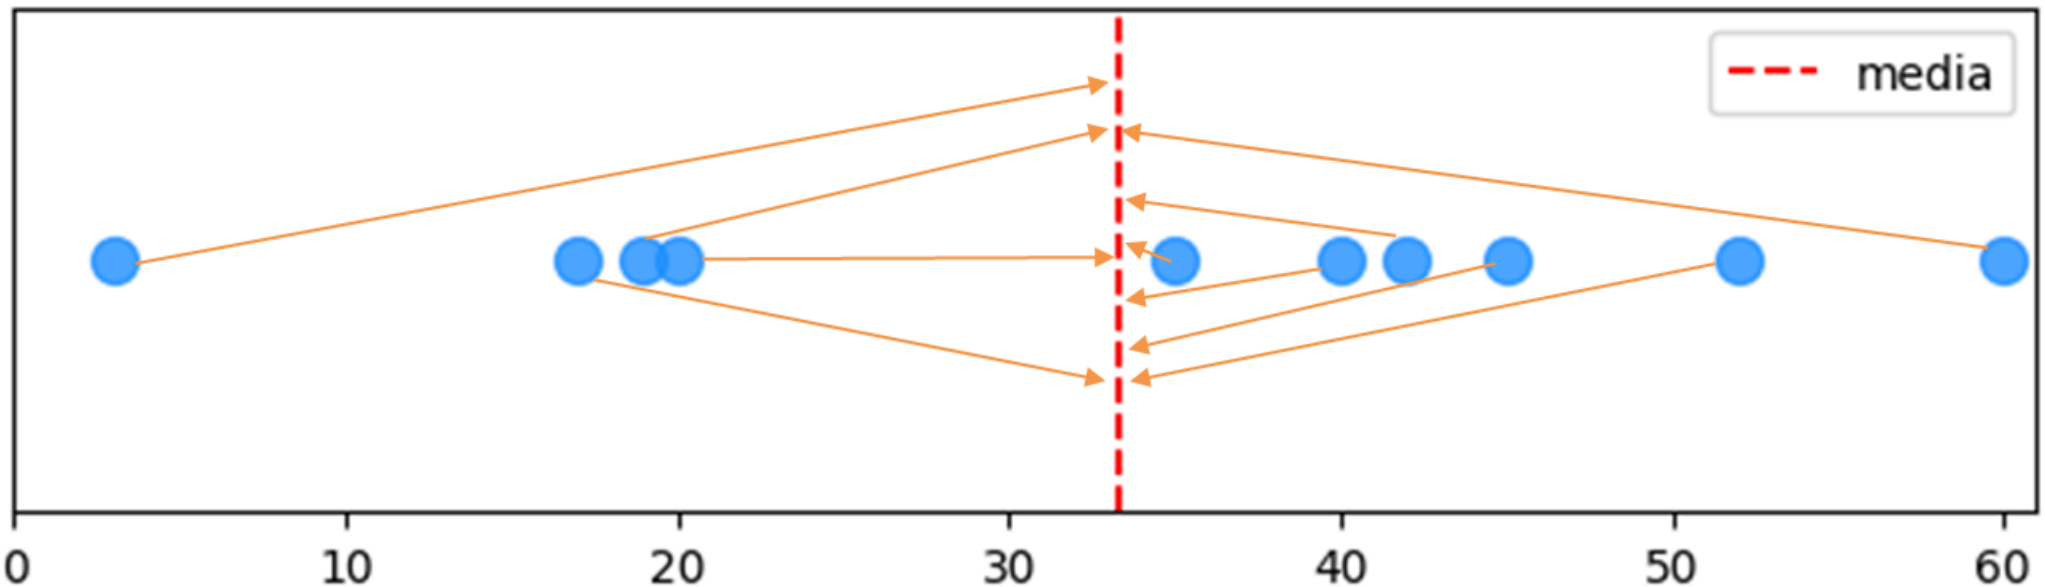

¿Qué tan distantes están los valores respecto a la media?

Varianza

	age	media	distancia	distancia^2
374	3	33.3	-30.3	918.09
840	20	33.3	-13.3	176.89
591	52	33.3	18.7	349.69
62	45	33.3	11.7	136.89
389	17	33.3	-16.3	265.69
715	19	33.3	-14.3	204.49
161	40	33.3	6.7	44.89
614	35	33.3	1.7	2.89
35	42	33.3	8.7	75.69
694	60	33.3	26.7	712.89

1. Calcular la media de la muestra.

2. Calcular la diferencia entre cada valor de la muestra y la media.

3. Elevar al cuadrado cada una de estas diferencias.

4. Sumar las diferencias y dividirlas en el tamaño de la muestra - 1 **(en el caso muestral)**

Varianza

¿Cómo calcularlo en Python?

```python
age = titanic["age"].sample(10, random_state=2024)

tmp["media"] = np.mean(tmp["age"])
tmp["distancia"] = tmp["age"] - tmp["media"]
tmp["distancia^2"] = tmp["distancia"] ** 2

print(np.sum(tmp["distancia^2"]) / (len(tmp) - 1))
```

```
320.90000000000003
```

```python
import numpy as np

np.var(tmp["age"], ddof=1)
```

```
np.float64(320.90000000000003)
```

Desviación Media Absoluta

- La desviación media absoluta, como su nombre lo indica, usa el valor absoluto de las distancias entre los valores y la media, y luego calcula la media de esas diferencias.
- $$DM = \frac{\sum |X_i - X|}{N}$$

¿Cómo calcularlo en Python?

```
age = titanic["age"].sample(10, random_state=2024)
mean_age = np.mean(age)

abs_distance = np.abs(age - mean_age)
dm = np.mean(abs_distance)
print(dm)
```

DM vs STD

Tomemos una muestra de 10 edades:

```
edades
```

```
[np.int32(3),
 np.int32(20),
 np.int32(52),
 np.int32(45),
 np.int32(17),
 np.int32(19),
 np.int32(40),
 np.int32(35),
 np.int32(42),
 np.int32(60)]
```

Desviación estándar

```
np.std(edades, ddof=1)
```

```
np.float64(17.913681921927722)
```

Agreguemos un valor extremo:

```
edades.append(80)
```

Volvemos a calcular la std

```
np.std(edades, ddof=1)
```

```
np.float64(22.069724222851704)
```

Desviación Media Absoluta

```
abs_distance = np.abs(edades - np.mean(edades))
dm = np.mean(abs_distance)
dm
```

```
np.float64(14.84)
```

Agreguemos un valor extremo:

```
edades.append(80)
```

Volvemos a calcular la dm

```
abs_distance = np.abs(edades - np.mean(edades))
dm = np.mean(abs_distance)
dm
```

```
np.float64(17.041322314049584)
```

¿Qué veremos hoy?

- Tipos de datos
- Medidas de tendencia central
- Medidas de dispersión
- **Cuartiles, percentiles e IQR**
- Outliers y resumen en Pandas

Cuartiles

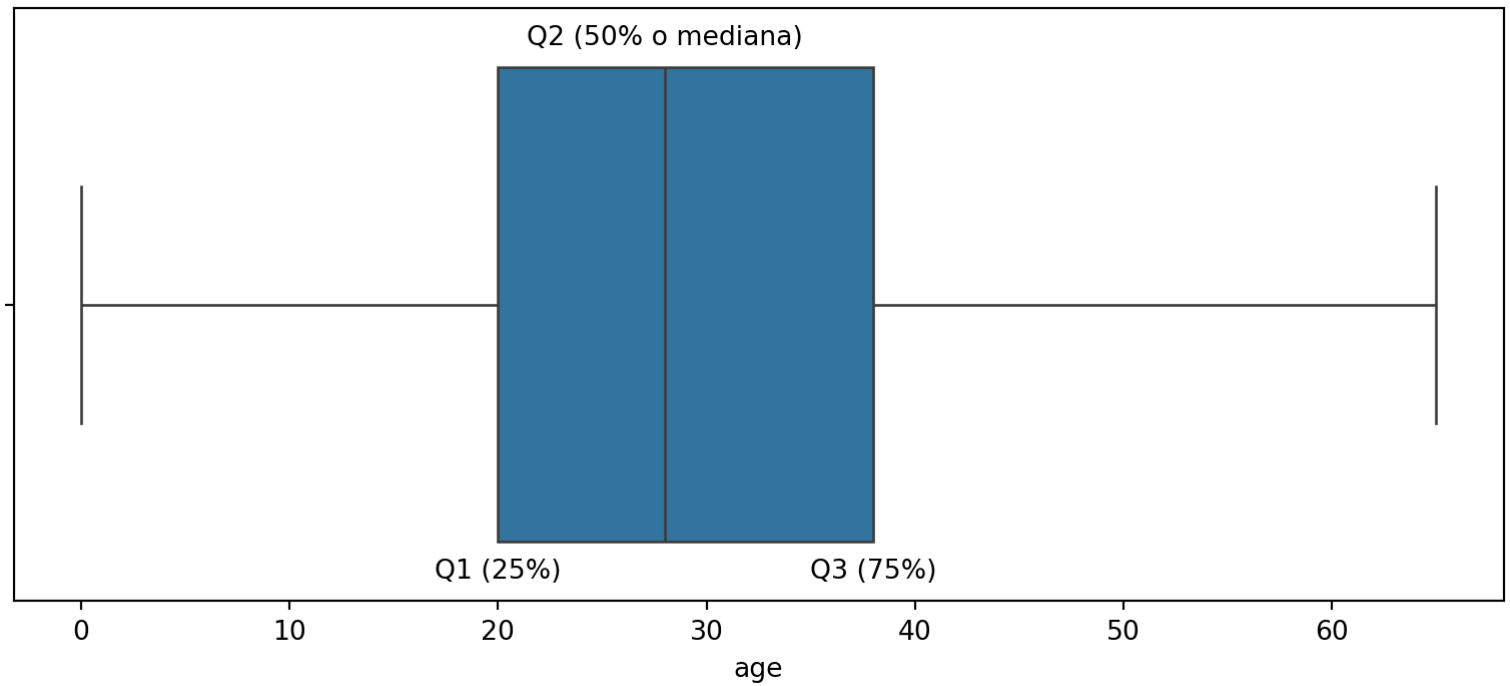

- El **primer cuartil** (Q_1), que es el valor por debajo del cual cae el 25% de los datos.
- El **segundo cuartil** (Q_2), que es la mediana y divide los datos en dos partes iguales (el 50% de los datos caen por debajo y el 50% por encima).
- Y el **tercer cuartil** (Q_3), que es el valor por debajo del cual cae el 75% de los datos.

Percentiles

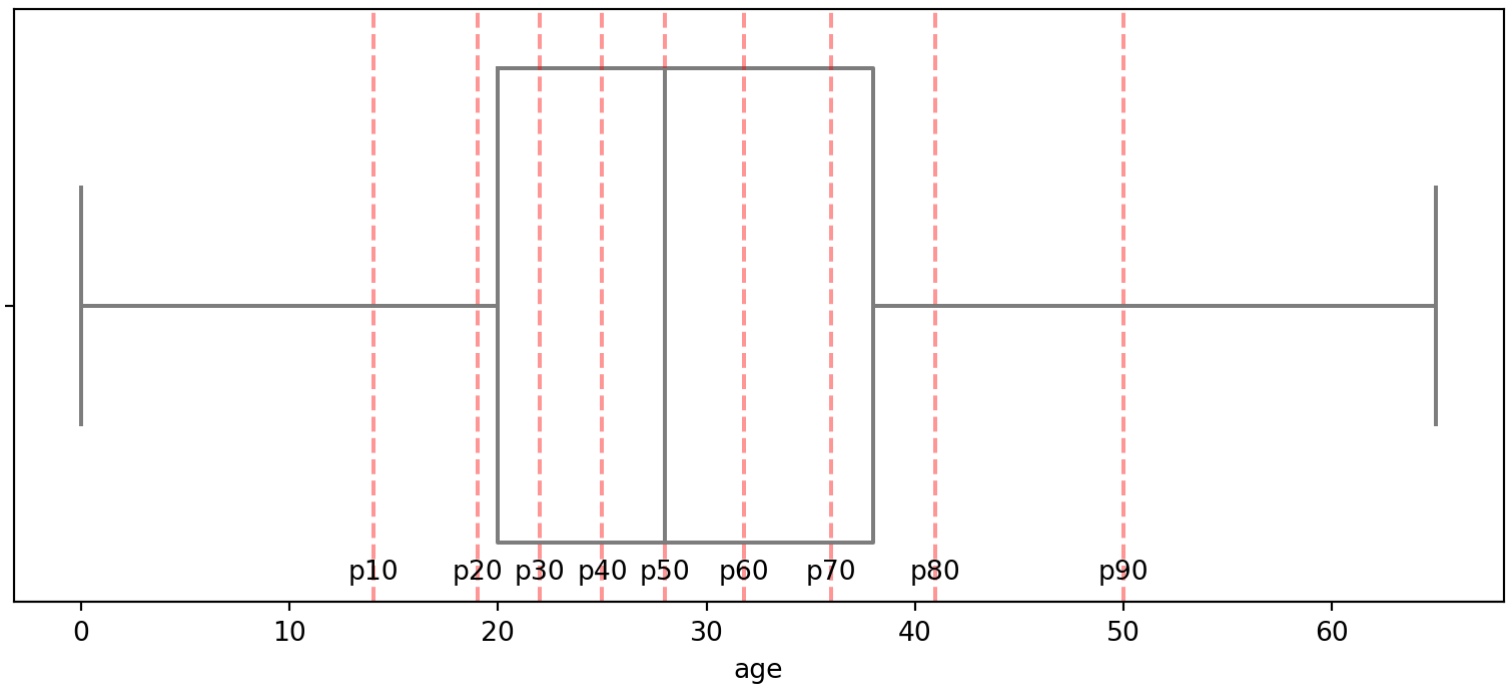

- Los percentiles se utilizan para **indicar la posición relativa de un valor dentro de un conjunto de datos**.
- Por ejemplo, el percentil 25 (P_{25}) es el valor por debajo del cual cae el 25% de los datos, y el percentil 75 (P_{75}) es el valor por debajo del cual cae el 75% de los datos.

Cuartiles y percentiles en Python

```
import numpy as np

np.quantile(titanic["age"], 0.25)
```

```
np.float64(20.0)
```

Podemos calcular más de un cuartil:

```
np.quantile(titanic["age"], [0, 0.25, 0.50, 0.75, 1])
```

```
array([ 0., 20., 28., 38., 80.])
```

No necesariamente tienen que ser múltiplos de 25

```
np.quantile(titanic["age"], [.1, .3, .6, .9])
```

```
array([14. , 22. , 31.8, 50. ])
```

Rango Intercuartil (IQR)

Volvamos a observar el gráfico de caja previamente generado:

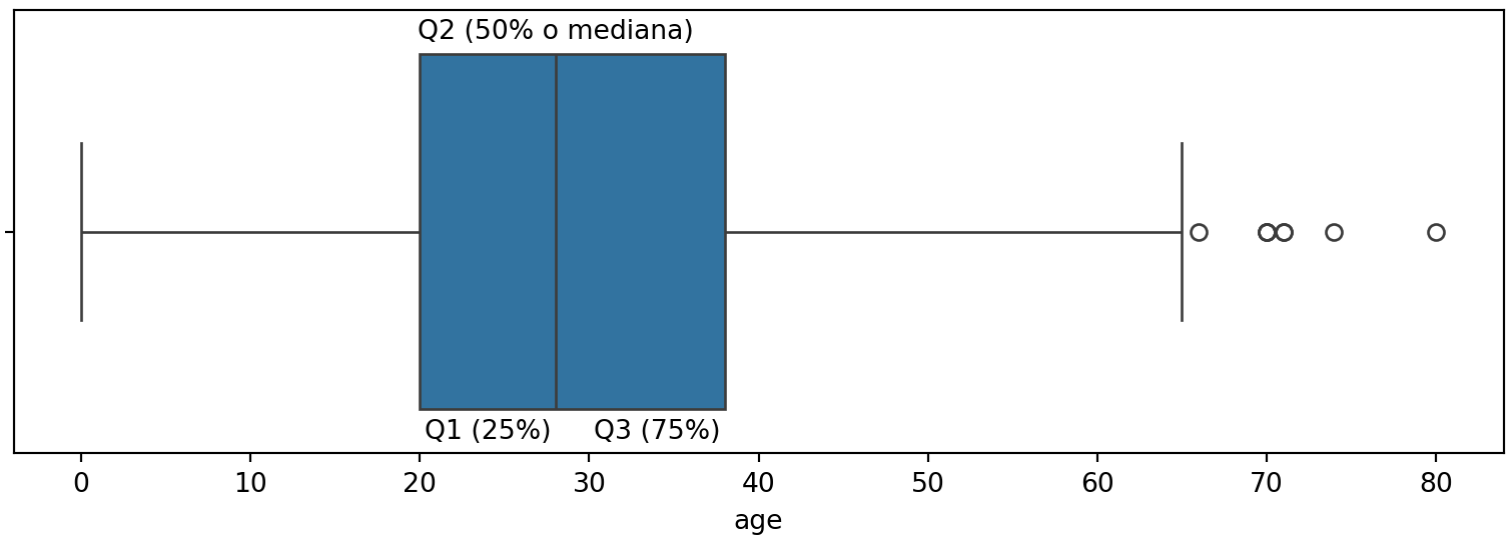

- ¿A qué se refieren esos puntos de datos que están alejados de la barra del máximo?
- Esos registros son llamados *outliers* o valores atípicos, y suelen identificarse como observaciones que quedan por debajo de $Q_1 - 1.5 \cdot IQR$ o por encima de $Q_3 + 1.5 \cdot IQR$.

Rango Intercuartil (IQR)

- El IQR también es otra medida de dispersión.
- Corresponde a la distancia entre el percentil 25 y el percentil 75, la cual se puede observar como el ancho de la caja en un *boxplot*.
- Esta medida es muy útil para detectar *outliers*, dado que suele servir como base para identificar valores extremos y poco frecuentes mediante la regla de $1.5 \cdot IQR$.

¿Cómo calcular en Python?

```python
import numpy as np

iqr = np.quantile(titanic["age"], 0.75) - np.quantile(titanic["age"], 0.25)
iqr
```

```
np.float64(18.0)
```

```python
from scipy.stats import iqr

iqr = iqr(titanic["age"])
iqr
```

```
np.float64(18.0)
```

¿Qué veremos hoy?

- Tipos de datos
- Medidas de tendencia central
- Medidas de dispersión
- Cuartiles, percentiles e IQR
- **Outliers y resumen en Pandas**

Outliers

- Observamos que el IQR es útil para determinar distancia entre Q_1 y Q_3, pero, ¿cómo determinamos si un registro es un *outlier* a partir de esto?
- Para realizar esta tarea, existe la siguiente fórmula:
- Limite inferior = $Q_1 - (1.5 * IQR)$
- Limite superior = $Q_3 + (1.5 * IQR)$

Outliers

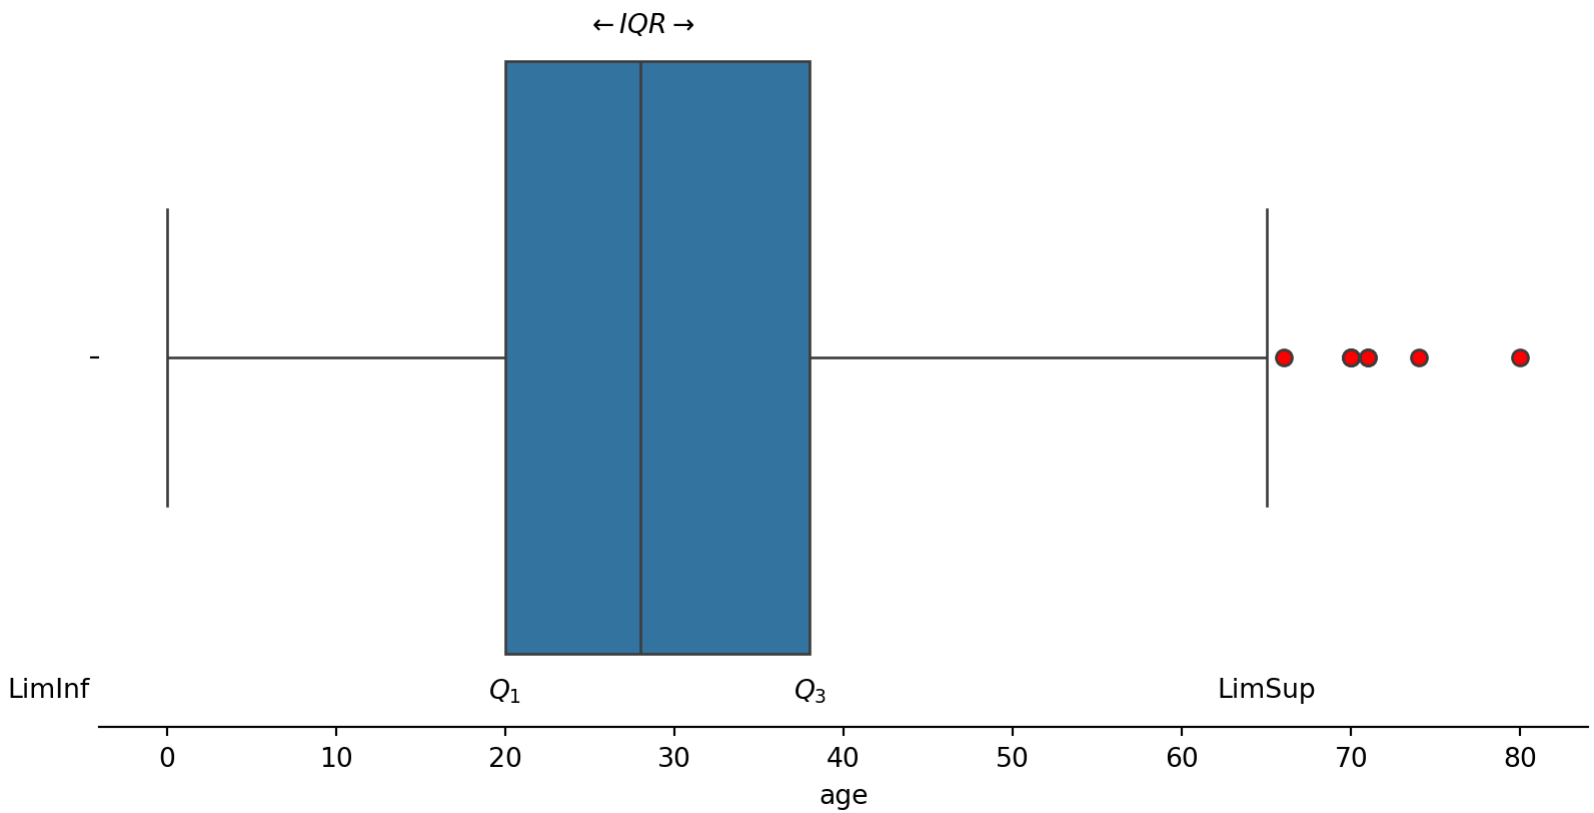

Outliers

¿Cómo calcular en Python?

```python
from scipy.stats import iqr

age = titanic["age"]

q1 = np.quantile(age, .25)
q3 = np.quantile(age, .75)

iqr = iqr(titanic["age"])
lim_inf = q1 - (1.5 * iqr)
lim_sup = q3 + (1.5 * iqr)

print(f"Limite Inferior: {lim_inf}")
print(f"Limite Superior: {lim_sup}")
```

```
Limite Inferior: -7.0
Limite Superior: 65.0
```

```python
outliers = age[(age < lower) | (age > upper)]
print(outliers.values)
```

```
[66 71 70 71 80 70 70 74]
```

Obtener estadísticas con Pandas

```
1  titanic["age"].describe()
```

```
count    714.000000
mean      29.679272
std       14.536483
min        0.000000
25%       20.000000
50%       28.000000
75%       38.000000
max       80.000000
Name: age, dtype: float64
```

```
1  titanic["sex"].describe()
```

```
count      714
unique       2
top       male
freq       453
Name: sex, dtype: object
```

Bibliografía recomendada

- Estadística, Capítulo 1, Triola Mario F, 2018 12a edición.
- Estadística, Capítulo 3, Triola Mario F, 2018 12a edición.
- Introducción a la Estadística, Capítulo 3, Sheldon M. Ross, 2014.