Métodos Cuantitativos

Clase 08 - Introducción a Pruebas de hipótesis

Unidad II: Test de Hipótesis y Regresión Lineal

Introducción

- En estadística, una **hipótesis es una afirmación o declaración** sobre una propiedad de una población.
- Una **prueba de hipótesis** es un **procedimiento diseñado para evaluar la validez de una hipótesis** relacionada con una característica poblacional.

Introducción

- La **característica de la población** mencionada suele referirse al valor de un parámetro poblacional. Por ejemplo:
  - $\mu < 25.2°C$: La temperatura media en una ciudad específica es menor que $25.2°C$.
  - $p > 0.5$: Más de la mitad de los consumidores se sienten a gusto con una determinada marca.
  - $\sigma = 15$: La desviación estándar de las puntuaciones de IQ de los estudiantes universitarios es de 15.

Introducción

- En cada uno de estos ejemplos, **el investigador formula una hipótesis sobre la población en estudio**. Al hacerlo, **realiza una afirmación** que luego **intentará confirmar o refutar**, enfocándose en uno o más parámetros poblacionales.
- Generalmente, **el investigador no dispone de toda la información de la población**, por lo que **debe recurrir a muestras para evaluar la veracidad de su hipótesis**.

¿Qué veremos hoy?

- **Fundamentos de la prueba de hipótesis**
- Valor crítico
- Prueba de una cola
- Valor-p
- Principales pruebas estadísticas

Prueba de hipótesis

Prueba de hipótesis

- El procedimiento implica plantear dos hipótesis:
  - H_0: Hipótesis nula (generalmente asociada a situaciones de no cambio)
  - H_1: Hipótesis alternativa (generalmente asociada a situación efectiva de cambio)
- Una prueba de hipótesis se basa en evidencia empírica y en distribuciones de probabilidad, para determinar si la **hipótesis nula** H_0 es una afirmación razonable.

Prueba de hipótesis

En general, una prueba de hipótesis tiene pasos ordenados a seguir:

Prueba de hipótesis

Entonces, ¿qué es H_0 y H_1?

- H_0 es la hipótesis nula, la cual representa la afirmación de que *no existe efecto* o *no hay diferencia* en los parámetros involucrados.
- H_1 es la hipótesis alternativa, la cual como investigadores conjeturamos, donde establecemos el efecto a evaluar.

Prueba de hipótesis

Consideremos, por ejemplo, un estudio sobre el rendimiento académico en la asignatura de Métodos Cuantitativos entre estudiantes de la UST y la UDP.

- H_0: **No hay diferencia en el rendimiento académico** entre los estudiantes de la UST y los de la UDP en Métodos Cuantitativos.
- $\mu_{ust} = \mu_{udp}$

Prueba de hipótesis

Consideremos, por ejemplo, un estudio sobre el rendimiento académico en la asignatura de Métodos Cuantitativos entre estudiantes de la UST y la UDP.

- H_0: Los estudiantes de la UST **no muestran un rendimiento académico superior** que los estudiantes de la UDP en Métodos Cuantitativos.
- $\mu_{ust} \leq \mu_{udp}$

Prueba de hipótesis

- Tanto la aceptación como el rechazo de H_0 dependen de los resultados de evidencia empírica muestral, lo cual puede estar sujeto a **posibles errores asociados**.

Prueba de hipótesis: Error Tipo I

- Error Tipo I: $P(\text{rechazar } H_0/H_0 \text{ es verdadera})$
- La probabilidad Tipo I se denota como α, la cual corresponde al **nivel de significancia** de la prueba de hipótesis.
- La probabilidad real de cometer Error Tipo I se conoce como **valor-p**.

Prueba de hipótesis: Error Tipo II

- Error Tipo II: $P(\text{no rechazar } H_0/H_0 \text{ es falsa})$
- Se denota β al Error Tipo II en una prueba de hipótesis teniendo en cuenta el nivel de significancia α.
- El complemento $1 - \beta$ se conoce como la potencia de la prueba.
- **Potencia**: Es la probabilidad de que la prueba rechace correctamente la hipótesis nula.

Prueba de hipótesis: Errores de decisión

Entonces, ¿qué es el Error de Tipo I?

Rechazar la hipótesis nula (H_0) cuando en realidad esta es verdadera.

Entonces, ¿qué es el Error de Tipo II?

Aceptar la hipótesis nula (H_0) cuando en realidad esta era falsa.

Prueba de hipótesis: Errores de decisión

	no rechazar H_0	rechazar H_0
H_0 es cierta	Correcto Probabilidad $1-\alpha$	Error tipo I Probabilidad α
H_0 es falsa	Error tipo II Probabilidad β	Correcto Probabilidad $1-\beta$

Prueba de hipótesis: Criterio de decisión

Supongamos que queremos determinar si el promedio de la asignatura de Métodos Cuantitativos de los alumnos de la UST es igual a 55.

- Para realizar la prueba de hipótesis, formulamos las siguientes inferencias respecto a la población:
  - $H_0 : \mu = 55$
  - $H_1 : \mu \neq 55$
- Con los datos muestrales disponibles, podemos decidir si rechazamos o no rechazamos H_0.

Prueba de hipótesis: Criterio de decisión

Supongamos que al calcular la media muestral del curso, obtenemos una nota de 56.

- ¿Se puede concluir que la media poblacional no es 55?
- **Probablemente no**. Esta diferencia podría deberse a un error de muestreo.
- En este caso, la diferencia se consideraría *estadísticamente insignificante*. El desafío radica en determinar qué tan grande debe ser una diferencia para considerarla estadísticamente significativa.

¿Qué veremos hoy?

- Fundamentos de la prueba de hipótesis
- **Valor crítico**
- Prueba de una cola
- Valor-p
- Principales pruebas estadísticas

Valor crítico

Prueba de hipótesis: Valor crítico

- Recordando las distribuciones, podemos aplicar la fórmula Z para el caso muestral:
- $Z = \frac{\overline{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$
- Si la varianza poblacional es desconocida, podemos utilizar la varianza muestral.
- La regla empírica indica que el 95% de las veces la media muestral esta a **1.96 desviaciones de la media poblacional**.

Prueba de hipótesis: Valor crítico

```
import matplotlib.pyplot as plt
import numpy as np
import scipy.stats as stats

mu = 0
sigma = 1

x = np.linspace(mu - 4*sigma, mu + 4*sigma, 1000)
y = stats.norm.pdf(x, mu, sigma)

plt.figure(figsize=(10, 6))
plt.plot(x, y, label='Distribución Normal', color="gray")

plt.fill_between(x, y, where=np.abs(x-mu) <= 3*sigma, color='tab:red', alph
plt.fill_between(x, y, where=np.abs(x-mu) <= 2*sigma, color='forestgreen',
plt.fill_between(x, y, where=np.abs(x-mu) <= sigma, color='tab:blue', alpha

plt.title('Distribución Normal con la regla 68-95-99.7')
```

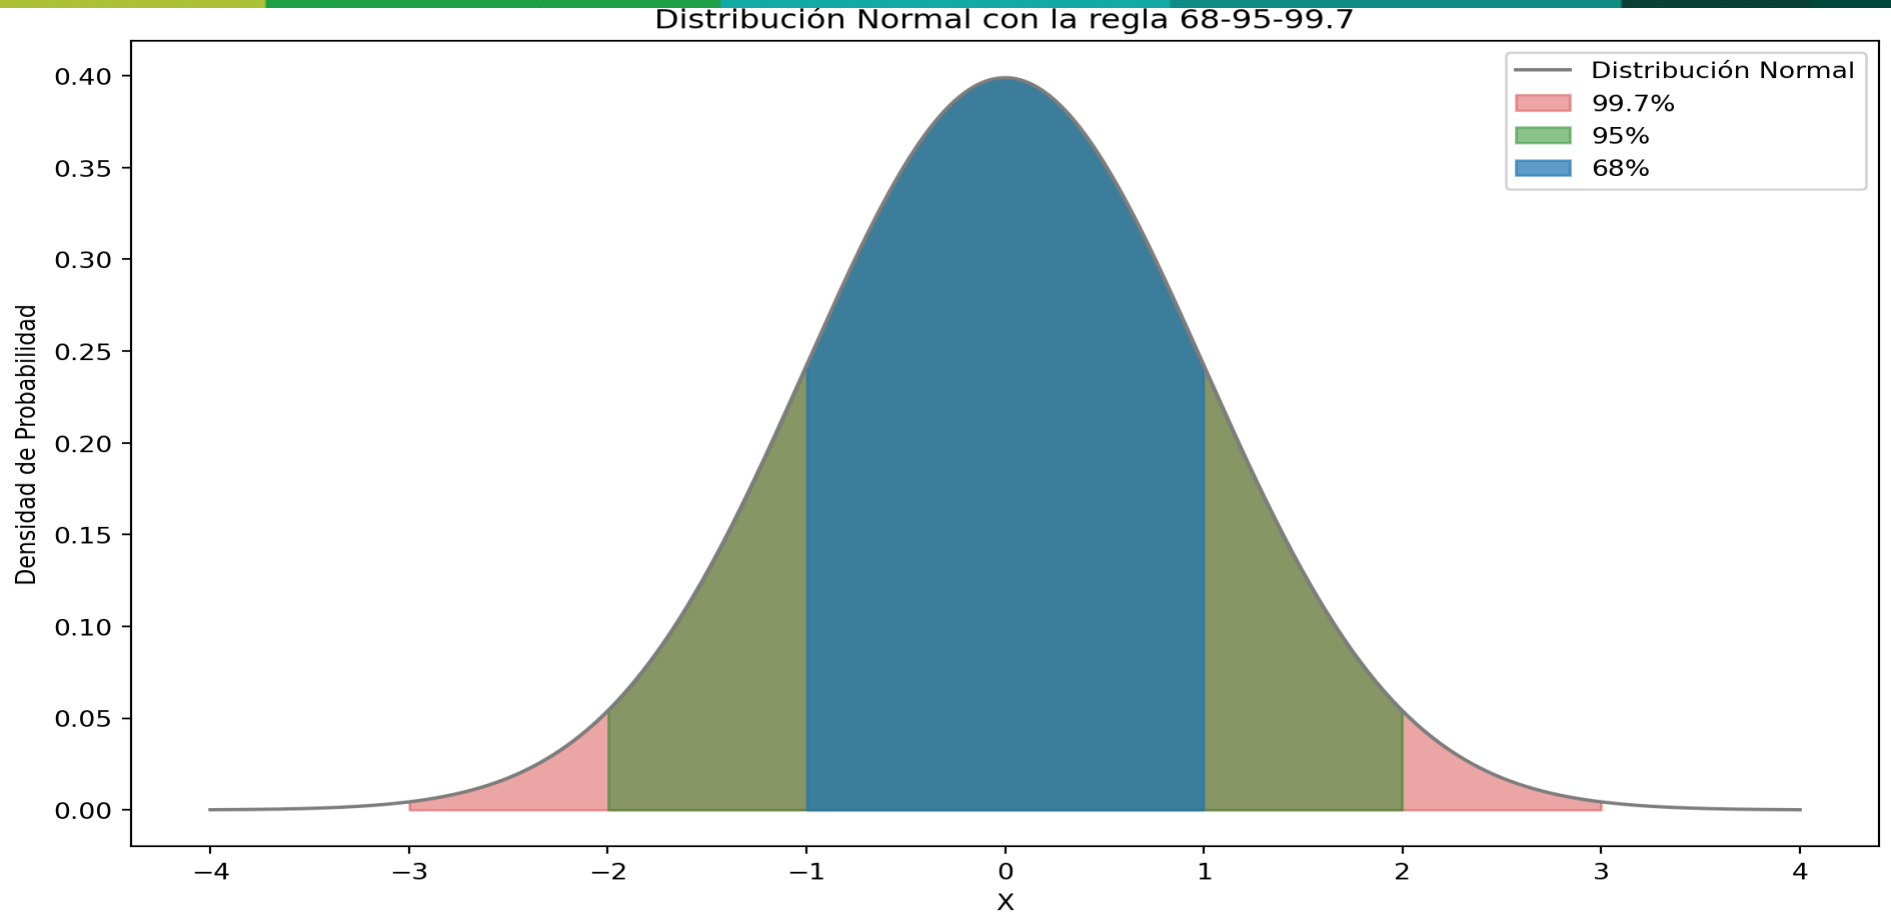
Distribución Normal con la regla 68-95-99.7
Distribución Normal
99.7%
95%
68%
Densidad de Probabilidad
0.40
0.35
0.30
0.25
0.20
0.15
0.10
0.05
0.00
−4
−3
−2
−1
0
1
2
3
4
X

Prueba de hipótesis: Valor crítico

- La regla empírica establece que para una distribución normal:
  - Aproximadamente el **68% de los datos caen dentro de una desviación estándar de la media**.
  - Aproximadamente el **95% de los datos caen dentro de dos desviaciones estándar de la media**.
  - Aproximadamente el **99.7% de los datos caen dentro de tres desviaciones estándar de la media**.

Prueba de hipótesis: Valor crítico

- Entonces, cuando afirmamos que "*el 95% de las veces, la media muestral está a 1.96 desviaciones estándar de la media poblacional*", nos referimos a:
  - Si repetimos el muestreo muchas veces, el 95% de las medias muestrales estarán dentro del rango de **1.96 desviaciones estándar por encima o por debajo de la media poblacional**.

Prueba de hipótesis: Valor crítico

```
import matplotlib.pyplot as plt
import numpy as np
import scipy.stats as stats

mu = 0
sigma = 1
x = np.linspace(mu - 4*sigma, mu + 4*sigma, 1000)
y = stats.norm.pdf(x, mu, sigma)

z_critical = 1.96

plt.figure(figsize=(10, 6))
plt.plot(x, y, label='Distribución Normal', color='lightblue')

plt.fill_between(x, y, where=(x <= -z_critical), color='lightcoral', alpha=
plt.fill_between(x, y, where=(x >= z_critical), color='lightcoral', alpha=0
plt.fill_between(x, y, where=(x > -z_critical) & (x < z_critical), color='w

```

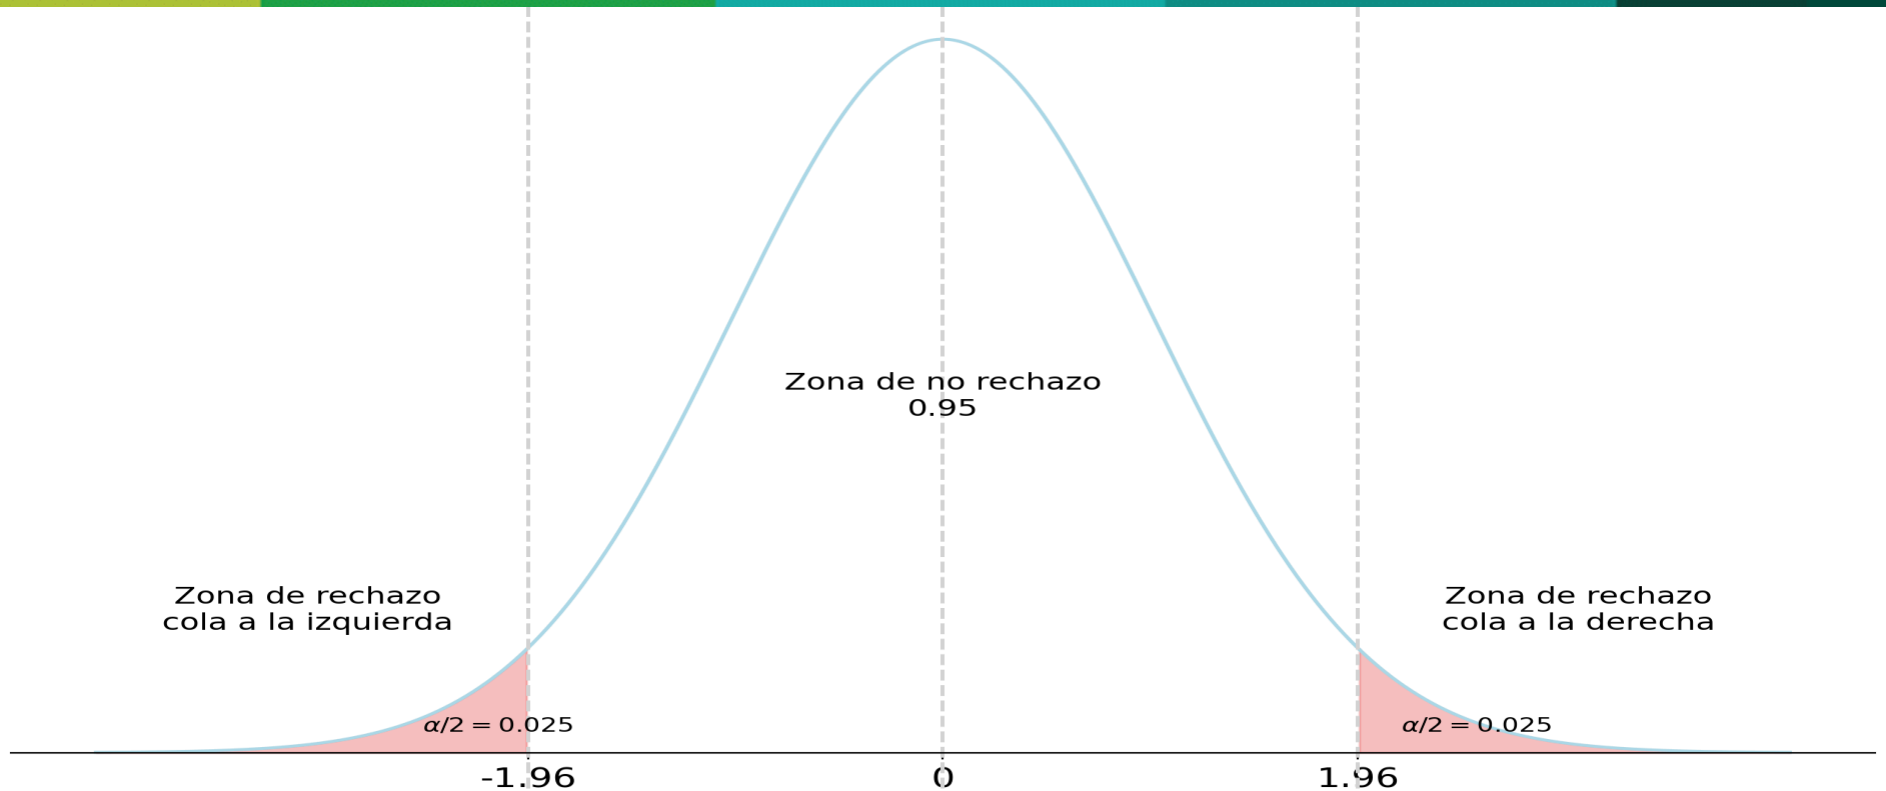

Existe un 95% de probabilidad de que los resultados muestrales puedan caer entre ± 1.96 si H_0 es verdadera

Prueba de hipótesis: Valor crítico

- Valores críticos de $Z \pm 1.96$ permiten establecer una regla de decisión que diga si se rechaza la hipótesis nula o no:
  - No se rechaza H_0 si los valores Z están entre ± 1.96.
  - Se rechaza H_0 si el valor de Z es menor que -1.96 o mayor que 1.96.

Prueba de hipótesis: Valor crítico

Prueba de hipótesis: Valor crítico

- Primero, calculamos el error estándar de la media (la desviación estándar de la distribución muestral):
  - Error estándar $= \frac{\sigma}{\sqrt{n}} = \frac{3}{\sqrt{30}} \approx 0.5477$
- Luego calculamos el puntaje Z:
  - $Z = \frac{56-55}{0.5477} \approx 1.825$
- Ahora, comparamos este valor Z con los valores críticos para un nivel de significancia (α) del 5% (nivel de confianza del 95%). Para una prueba de dos colas, los valores críticos son ± 1.96.

Prueba de hipótesis: Valor crítico

- La regla empírica y los valores críticos nos indican que:
  - Si el valor Z calculado está entre -1.96 y 1.96, no rechazamos H_0.
  - Si el valor Z calculado está fuera de este rango, rechazamos H_0.
- En nuestro ejemplo, el valor Z es 1.825, que está dentro del rango de -1.96 y 1.96. Por lo tanto, **fallamos en rechazar** H_0.

Prueba de hipótesis: Valor crítico

- Esto significa que la diferencia observada entre la media muestral (56) y la media poblacional (55) podría deberse al error de muestreo y no es lo suficientemente grande como para considerarse estadísticamente significativa.
- En resumen, aunque la media muestral es 56, no tenemos suficiente evidencia para concluir que la media poblacional es diferente de 55 con un nivel de confianza del 95%.

Digresión: ¿Por qué 1.96?

```python
from scipy.stats import norm

# establecer el nivel de significancia
alpha = 0.05

# calcular el área de la cola
area_cola = 1 - (alpha / 2)

# parámetros distribución normal
mu = 0
sigma = 1

# obtener el valor del estadístico crítico
z_critical = norm.ppf(area_cola)

# imprimir valor
print(round(z_critical, 3))
```

```
1.96
```

¿Qué veremos hoy?

- Fundamentos de la prueba de hipótesis
- Valor crítico
- **Prueba de una cola**
- Valor-p
- Principales pruebas estadísticas

Prueba de hipótesis: Prueba de una cola

- En algunos casos, solo nos interesa un extremo de la distribución, ya sea el inferior o el superior, por ejemplo:
  - Un restaurante de comida fresca no se interesa en saber qué tan rápidos son sus proveedores, sólo si toman demasiado tiempo.
  - Un minorista se alarmará sólo si sus ingresos son demasiado bajos, ventas altas no son un problema.

Prueba de hipótesis: Prueba de una cola

$$H_0 : \mu \leq 55 \text{ vs } H_1 : \mu > 55$$

```python
import matplotlib.pyplot as plt
import numpy as np
import scipy.stats as stats

mu = 0
sigma = 1
x = np.linspace(mu - 4*sigma, mu + 4*sigma, 1000)
y = stats.norm.pdf(x, mu, sigma)

alpha = 0.05
z_critical = stats.norm.ppf(1 - alpha)

plt.figure(figsize=(10, 5))
plt.plot(x, y, label='Distribución Normal', color='lightblue')

plt.fill_between(x, y, where=(x >= z_critical), color='lightcoral', alpha=0
plt.fill_between(x, y, where=(x < z_critical), color='white', alpha=0.5, la
plt.axvline(z_critical, color='lightgray', linestyle='--')
```

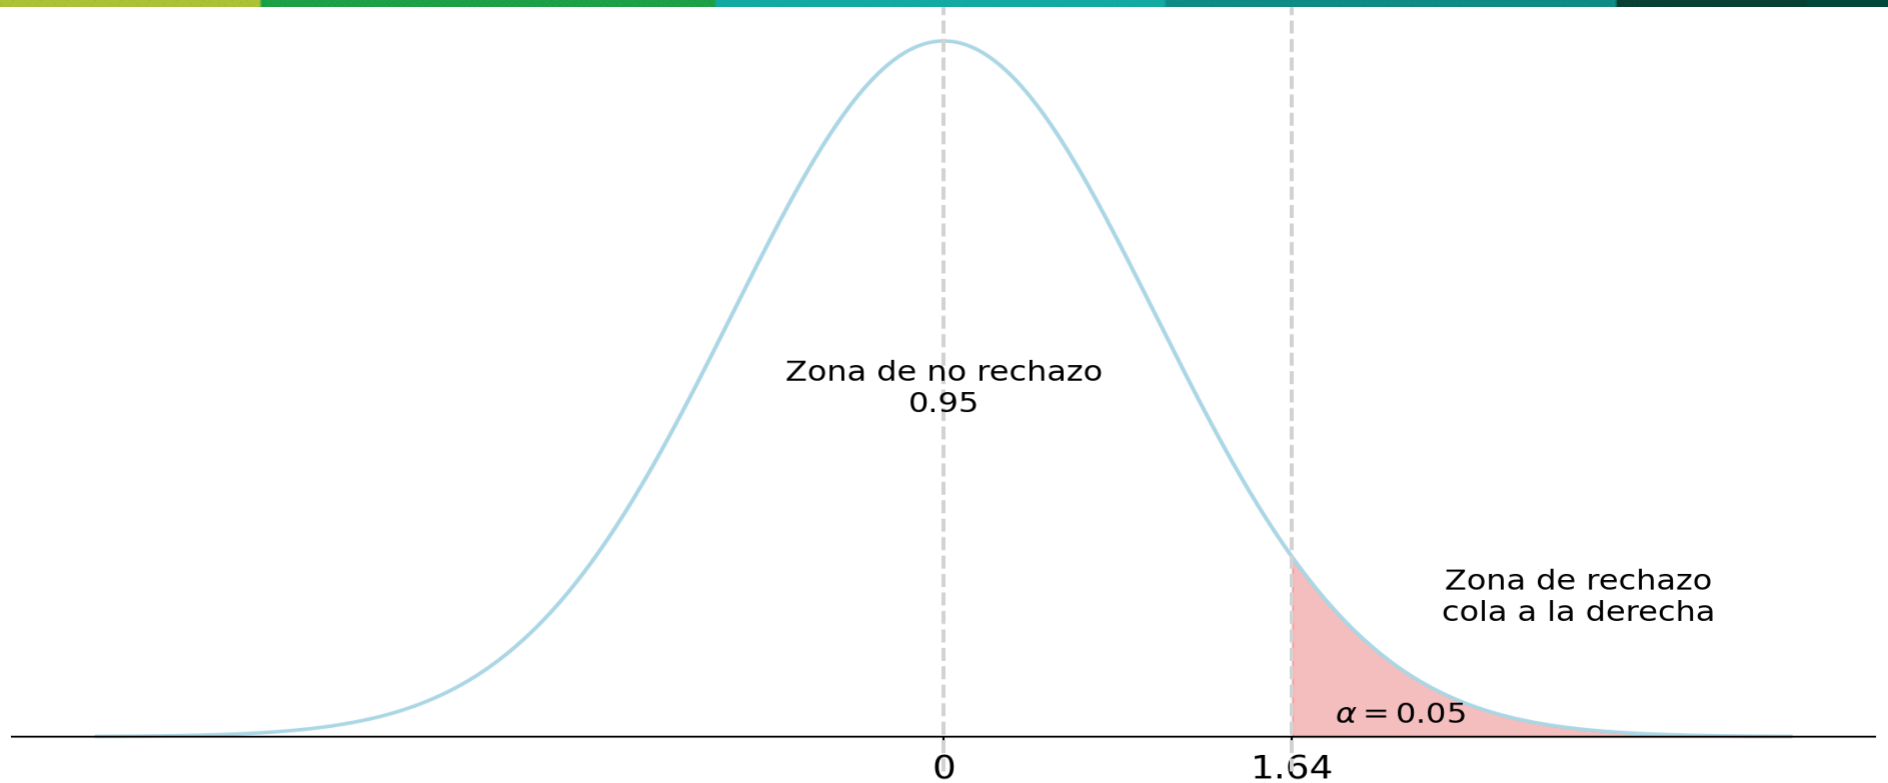

Existe un 95% de probabilidad de que los resultados muestrales puedan caer a la izquierda de 1.645 si la hipótesis nula es verdadera

Prueba de hipótesis: Prueba de una cola

$$H_0 : \mu \geq 55 \text{ vs } H_1 : \mu < 55$$

```
mu = 0
sigma = 1
x = np.linspace(mu - 4*sigma, mu + 4*sigma, 1000)
y = stats.norm.pdf(x, mu, sigma)

alpha = 0.05
z_critical = stats.norm.ppf(alpha)

plt.figure(figsize=(10, 5))
plt.plot(x, y, label='Distribución Normal', color='lightblue')

plt.fill_between(x, y, where=(x <= z_critical), color='lightcoral', alpha=0
plt.fill_between(x, y, where=(x > z_critical), color='white', alpha=0.5, la
plt.axvline(z_critical, color='lightgray', linestyle='--')

plt.text(z_critical - 0.8, 0.02, f'$\\alpha = {alpha}$', fontsize=12, verti

plt.axvline(mu, color='lightgray', linestyle='--')
```

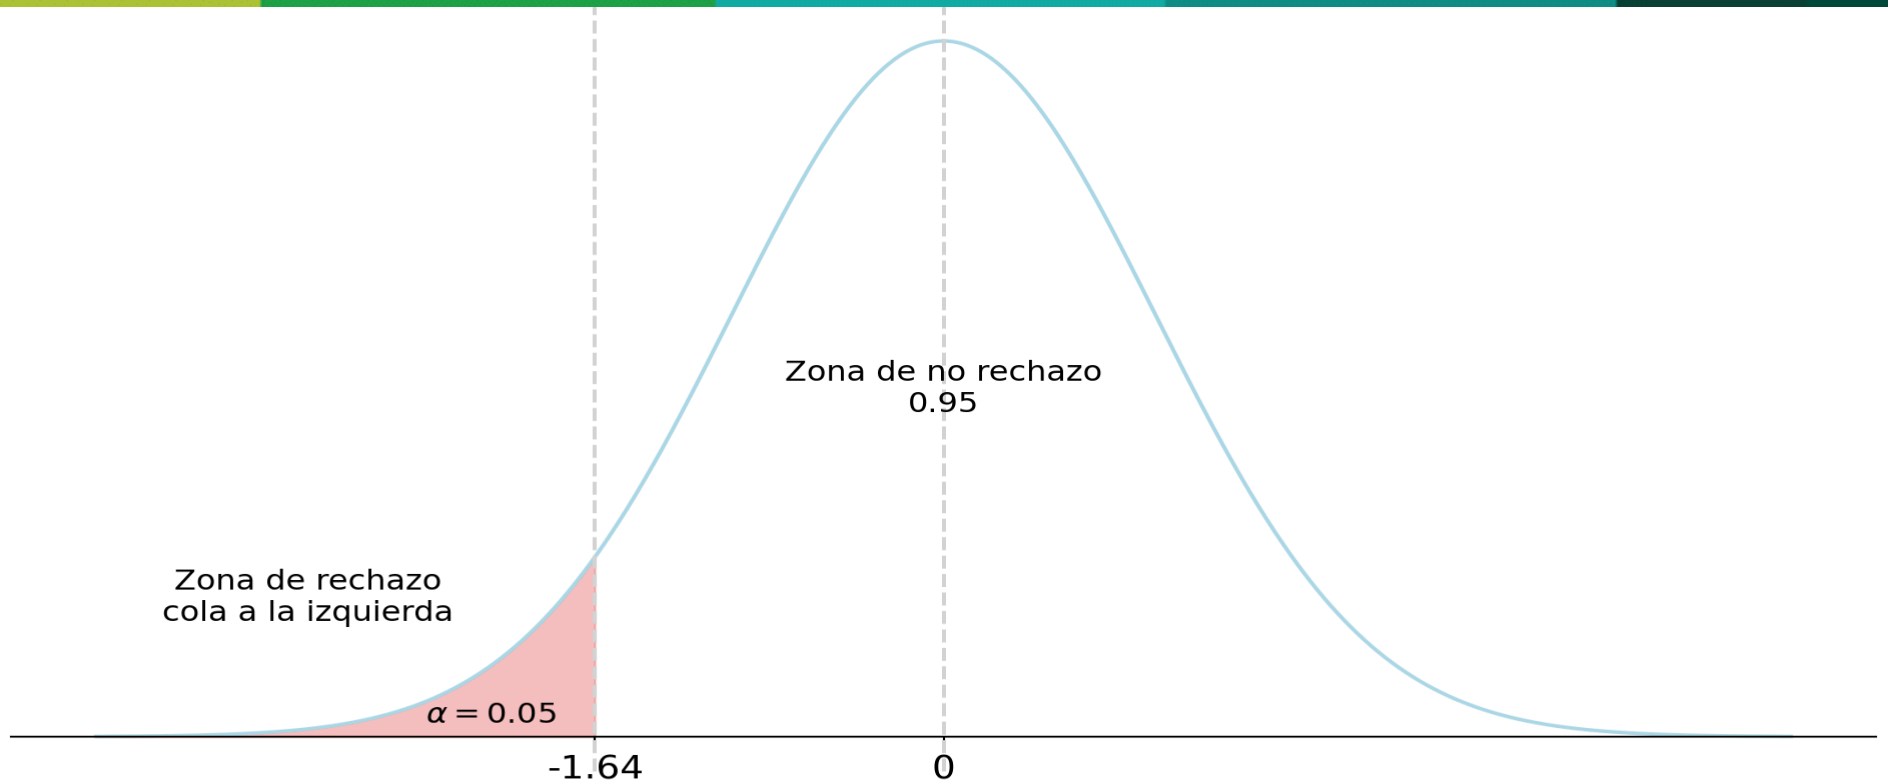

Existe un 95% de probabilidad de que los resultados muestrales puedan caer a la derecha de -1.645 si la hipótesis nula es verdadera

Prueba de hipótesis: Prueba de una cola

- Volviendo al ejemplo de las notas del curso, en lugar de preguntarnos si el promedio de la asignatura es igual a 55, podemos plantear la hipótesis nula que el promedio sea **"al menos 55"**, versus un promedio mayor a 55.
  - $H_0 : \mu \leq 55$
  - $H_1 : \mu > 55$
- En este caso sólo los valores significativamente por arriba pueden ser causa del rechazo de la H_0. Ahora si considera el 5% superior como zona de rechazo.

Prueba de hipótesis: Prueba de una cola

- $Z = \frac{56-55}{\frac{3}{\sqrt{30}}} \approx 1.825$
- Para un nivel de significancia de $\alpha = 0.05$ en una cola derecha, el valor crítico de Z es aproximadamente 1.645.
- Como $Z \approx 1.825$ es mayor 1.645, rechazamos H_0.
- Con un nivel de significancia del 5%, tenemos suficiente evidencia para rechazar H_0 y concluir que el promedio de la asignatura es significativamente mayor a 55.

Prueba de hipótesis: Diferencias en resultados

- La diferencia en los resultados se debe a la posición y el tamaño de las zonas de rechazo en las dos pruebas:
  - En la prueba de dos colas, el área total de α se divide entre las dos colas, lo que hace que los valores críticos sean más extremos (± 1.96)
  - En la prueba de una cola, todo el α se concentra en una cola, haciendo que el valor crítico sea menos extremo (1.645).

Prueba de hipótesis: Diferencias en resultados

- Por lo tanto, una media muestral que no sea suficientemente extrema para rechazar H_0 en una prueba de dos colas puede ser suficiente para rechazar H_0 en una prueba de una cola debido a la diferencia en los valores críticos.

Prueba de hipótesis: Criterio de decisión

- Hasta ahora hemos aprendido cómo formular y evaluar hipótesis utilizando estadísticos de prueba y valores críticos.
- Sin embargo, hay otro enfoque muy utilizado en pruebas de hipótesis: el **valor-p**.

¿Qué veremos hoy?

- Fundamentos de la prueba de hipótesis
- Valor crítico
- Prueba de una cola
- **Valor-p**
- Principales pruebas estadísticas

Prueba de hipótesis: Valor-p

Prueba de hipótesis: Valor-p

- El valor-p es la probabilidad de obtener un resultado tan extremo como el observado, o más extremo, bajo la suposición de que la hipótesis nula (H_0) es verdadera.
- El **valor-p nos ayuda a determinar la significancia de nuestros resultados sin depender de un valor crítico específico**.

Prueba de hipótesis: Valor-p

¿Cómo interpretar el valor-p?

Prueba de hipótesis: Valor-p

- En una prueba de hipótesis, comparamos el valor-p con un umbral de significancia (α) para tomar una decisión:
  - Si el valor-p $\leq \alpha$, rechazamos H_0.
  - Si el valor-p $> \alpha$, no rechazamos H_0.

Pruebas de hipótesis en Python

Prueba de dos colas

```python
from scipy.stats import ttest_1samp

# datos
media_poblacional = 55
alpha = 0.05

# creamos una muestra simulada para realizar el test
muestra = np.array([52, 50, 55, 51, 58, 59, 55, 53, 56, 57, 58, 59, 55, 56,
                    55, 54, 53, 52, 51, 50, 49, 60, 60, 61, 62, 63, 64, 65]
)

# prueba de dos colas
# H0: media_muestral = 55 vs H1: media_muestral != 55
t_stat, p_value = ttest_1samp(muestra, media_poblacional, alternative='two-

# resultados
print("H0: media_muestral = 55 vs H1: media_muestral != 55")
print(f"Valor-p: {p_value}")
```

```
H0: media_muestral = 55 vs H1: media_muestral != 55
Valor-p: 0.12063570605176656
```

Pruebas de hipótesis en Python

Prueba de una cola

```python
from scipy.stats import ttest_1samp

# datos
media_poblacional = 55
alpha = 0.05

# creamos una muestra simulada para realizar el test
muestra = np.array([52, 50, 55, 51, 58, 59, 55, 53, 56, 57, 58, 59, 55, 56,
                    55, 54, 53, 52, 51, 50, 49, 60, 60, 61, 62, 63, 64, 65]
)

# prueba de una cola
# H0: media_muestral <= 55 vs H1: media_muestral > 55
t_stat, p_value = ttest_1samp(muestra, media_poblacional, alternative='grea

# resultados
print("H0: media_muestral <= 55 vs H1: media_muestral > 55")
print(f"Valor-p: {p_value}")
```

```
H0: media_muestral <= 55 vs H1: media_muestral > 55
Valor-p: 0.06031785302588328
```

Pruebas de hipótesis en Python

Prueba de una cola

```python
from scipy.stats import ttest_1samp

# datos
media_poblacional = 55
alpha = 0.05

# creamos una muestra simulada para realizar el test
muestra = np.array([52, 50, 55, 51, 58, 59, 55, 53, 56, 57, 58, 59, 55, 56,
                    55, 54, 53, 52, 51, 50, 49, 60, 60, 61, 62, 63, 64, 65]
)

# prueba de una cola
# H0: media_muestral >= 55 vs H1: media_muestral < 55
t_stat, p_value = ttest_1samp(muestra, media_poblacional, alternative='less

# resultados
print("H0: media_muestral >= 55 vs H1: media_muestral < 55")
print(f"Valor-p: {p_value}")
```

```
H0: media_muestral >= 55 vs H1: media_muestral < 55
Valor-p: 0.9396821469741168
```

Valor-p

¡No olvidar!

- Si el valor-p $\leq \alpha$, rechazamos H_0.
- Si el valor-p $> \alpha$, no rechazamos H_0.

p=0.0501
p=0.0499

Prueba de hipótesis: Parámetros

Prueba de hipótesis: Parámetros

Son tres parámetros poblacionales a los que les aplicaremos el procedimiento de una prueba de hipótesis:

Población	estadístico muestral
μ	$\overline{X}$
P	$\hat{P}$
σ	S

Prueba de hipótesis: media poblacional μ

- Hipótesis:
  - $H_0 : \mu = \mu_0$
  - $H_1 :$
    - $\mu \neq \mu_0$
    - $\mu < \mu_0$
    - $\mu > \mu_0$
- Recolectar datos:
  - $\alpha, n, \overline{X}, S$ (o σ si se conoce)

Prueba de hipótesis: media proporción P

- Hipótesis:
  - $H_0 : P = P_0$
  - H_1 :
    - $P \neq P_0$
    - $P < P_0$
    - $P > P_0$
- Recolectar datos:
  - $\alpha, n, \hat{p}$

Prueba de hipótesis: varianza poblacional σ^2

- Hipótesis:
  - $H_0 : \sigma^2 = \sigma_0^2$
  - $H_1 :$
    - $\sigma^2 \neq \sigma_0^2$
    - $\sigma^2 < \sigma_0^2$
    - $\sigma^2 > \sigma_0^2$
- Recolectar datos:
  - α, n, S^2

¿Qué veremos hoy?

- Fundamentos de la prueba de hipótesis
- Valor crítico
- Prueba de una cola
- Valor-p
- **Principales pruebas estadísticas**

Prueba t

Prueba t

- La prueba t de Student es una prueba estadística que se utiliza para comparar la media de una muestra con la media de una población o para comparar las medias de dos muestras diferentes.
- Se usa principalmente cuando las muestras son pequeñas y las distribuciones de los datos son aproximadamente normales.

Prueba t: ¿Cuándo usar?

1. **Comparar una muestra con una media conocida**: Si tenemos una muestra de datos y necesitamos saber si su media es significativamente diferente de una media conocida o esperada.
2. **Comparar dos muestras independientes**: Si tenemos dos grupos diferentes y necesitamos saber si sus medias son significativamente diferentes.
3. **Comparar muestras relacionadas**: Si tenemos dos conjuntos de datos relacionados, como antes y después de un tratamiento en el mismo grupo de personas.

Prueba t: Tipos

1. **Prueba t para una muestra**: Compara la media de una sola muestra con una media conocida.
2. **Prueba t para dos muestras independientes**: Compara las medias de dos grupos independientes.
3. **Prueba t para muestras relacionadas (pareadas)**: Compara las medias de dos conjuntos de datos que están relacionados (por ejemplo, mediciones antes y después en el mismo grupo).

Prueba t: Ejemplo

- Supongamos que tenemos una muestra de estudiantes que han realizado una prueba y buscamos saber si su promedio es diferente de 75 puntos (la media esperada).

Prueba t: Ejemplo

1. Hipótesis:
   - $H_0 : \mu = 75$
   - $H_0 : \mu \neq 75$
2. Recopilar los datos y calcular la media y la desviación estándar de la muestra.
3. Calcular el valor t.
4. Calcular el valor p utilizando el valor t y la distribución t de Student.
5. Comparar el valor p con el nivel de significancia (α)

Prueba Z

Prueba Z

- El test Z es una prueba estadística que se utiliza para comparar la media de una muestra con la media de una población **cuando la desviación estándar de la población es conocida**, o para comparar las medias de dos muestras grandes.
- Se usa principalmente cuando las muestras son grandes ($n > 30$) y las distribuciones de los datos son aproximadamente normales.

Prueba Z: ¿Cuándo usar?

1. **Comparar una muestra con una media conocida**: Si tenemos una muestra de datos y necesitamos saber si su media es significativamente diferente de una media conocida o esperada.
2. **Comparar dos muestras independientes**: Si tenemos dos grupos diferentes y necesitamos saber si sus medias son significativamente diferentes (por ejemplo, hombres vs. mujeres en un estudio).

Prueba Z: Tipos

1. **Prueba Z para una muestra**: Compara la media de una sola muestra con una media conocida.
2. **Prueba Z para dos muestras independientes**: Compara las medias de dos grupos independientes.

Prueba Z: Ejemplo

- Supongamos que queremos saber si la altura promedio de los hombres en una ciudad es diferente de 175 cm (la media esperada).
- Sabemos que la desviación estándar de la altura de los hombres en esta ciudad es 10 cm.
- Tomamos una muestra aleatoria de 1000 hombres y encontramos que la media de la muestra es 176.5 cm.

Prueba Z: Ejemplo

1. Hipótesis:
   - $H_0 : \mu = 175$
   - $H_0 : \mu \neq 175$
2. Recopilar los datos y calcular la media de la muestra.
3. Calcular el valor Z.
4. Calcular el valor p utilizando el valor Z y la distribución normal estándar.
5. Comparar el valor p con el nivel de significancia (α)

Prueba Chi-cuadrado

Prueba Chi-cuadrado

- El test Chi-cuadrado es una prueba estadística que se utiliza para determinar si existe una diferencia significativa entre las frecuencias observadas y las frecuencias esperadas en una o más categorías.
- Se usa principalmente en datos categóricos.

Prueba Chi-cuadrado: ¿Cuándo usar?

1. **Prueba de independencia**: Para determinar si hay una asociación significativa entre dos variables categóricas.
2. **Prueba de bondad de ajuste**: Para determinar si una distribución observada difiere significativamente de una distribución esperada.

Prueba Chi-cuadrado: Tipos

1. **Prueba Chi-cuadrado de independencia**: Evalúa si dos variables categóricas son independientes.
2. **Prueba Chi-cuadrado de bondad de ajuste**: Evalúa si la distribución de una variable categórica sigue una distribución esperada.

Prueba Chi-cuadrado: Ejemplo

- Supongamos que queremos saber si hay una asociación entre el hábito de fumar (fumador/no fumador) y el resultado de una prueba de salud (positivo/negativo) en una muestra grande de personas.

Prueba Chi-cuadrado: Ejemplo

1. **Hipótesis**:

- H_0: El hábito de fumar y el resultado de la prueba de salud son independientes.
- H_1: El hábito de fumar y el resultado de la prueba de salud no son independientes.

Prueba Shapiro-Wilk

Prueba Shapiro-Wilk

- El Test de Shapiro-Wilk es una prueba estadística que se utiliza para determinar si un conjunto de datos se distribuye de manera normal.
- Es especialmente útil en tamaños de muestra pequeños (menos de 50 muestras), aunque puede usarse con muestras de hasta 2000.

Prueba Shapiro-Wilk: ¿Cuándo usar?

1. **Antes de otros tests**: Algunos tests estadísticos, como el ANOVA y las pruebas t, asumen que los datos siguen una distribución normal. El Test de Shapiro-Wilk puede ayudar a validar esta suposición.
2. **Análisis exploratorio de datos**: Utilizado comúnmente en la fase inicial de análisis para asegurar que la distribución de los datos no viola los supuestos de normalidad.

Prueba Shapiro-Wilk: Ejemplo

- Supongamos que tenemos una muestra de las puntuaciones obtenidas en una prueba de IQ, y deseamos verificar si estas puntuaciones se distribuyen normalmente.

Prueba Shapiro-Wilk: Ejemplo

1. Hipótesis:

- H_0: Los datos siguen una distribución normal.
- H_1: Los datos no siguen una distribución normal.

2. Recopilar los datos y observar la distribución.
3. Calcular el estadístico de Shapiro-Wilk y el valor-p asociado.
4. Comparar el valor-p con el nivel de significancia (α).

Prueba Shapiro-Wilk: Interpretación

- Si el valor p ≤ 0.05, se rechaza la hipótesis nula (H_0), lo que indica que los datos no se ajustan a una distribución normal.
- Si el valor p > 0.05, no hay evidencia suficiente para rechazar la hipótesis nula, lo que sugiere que los datos pueden considerarse normalmente distribuidos.

Resumen

Resumen

En general, el proceso de una prueba de hipótesis es:

1. Establecer las hipótesis.
2. Aplicar el test.
3. Determinar el nivel de significancia α (generalmente se usa 5%).
4. Comparar el valor-p del test con el nivel de significancia.
5. Rechazar o no rechazar H_0.

Resumen

- **Prueba t**: Comparar la media de una muestra con la media de una población o para comparar las medias de dos muestras diferentes.
- **Prueba Z**: Comparar la media de una muestra con la media de una población **cuando la desviación estándar de la población es conocida**, o para comparar las medias de dos muestras grandes.

Resumen

- **Prueba Chi-cuadrado**: Determinar si existe una diferencia significativa entre las frecuencias observadas y las frecuencias esperadas en una o más categorías.
- **Prueba Shapiro-Wilk**: Determinar si un conjunto de datos se distribuye de manera normal.

Bibliografía recomendada

- Estadística, Capítulo 8, Triola Mario F, 2018 12a edición.