Métodos Cuantitativos

Clase 16 - Integración de conceptos

Unidad III: Regresión Logística

Introducción

- A lo largo del curso aprendimos que **la estadística** y **la teoría de la probabilidad** nos dan herramientas para **modelar** cómo se comportan variables de distinta naturaleza (continua, discreta, binaria, etc.).

Introducción

En concreto, vimos que:

1. Las **distribuciones** describen la variabilidad y la forma de los datos.
2. **Pruebas de hipótesis** que permiten validar inferencias estadísticas.
3. Las **regresiones** (lineal y logística) permiten capturar la relación entre **múltiples predictores** y **una respuesta de interés**.
4. Los **GLM** presentan una **visión unificada** que extiende estos conceptos a diversos tipos de datos.

¿Qué veremos hoy?

- **Distribuciones de probabilidad**
- Pruebas de hipótesis
- Regresión lineal
- Regresión logística
- Técnicas de selección de variables y modelos

Distribuciones de probabilidad

Distribuciones continuas

- **Normal**:
  - Forma de “campana”, caracterizada por media (μ) y desviación estándar (σ).
  - Muy utilizada por el *Teorema Central del Límite*, aproximando la suma de muchas variables.
  - Importante en regresión lineal tradicional, donde se asume que los errores siguen (al menos aproximadamente) una Normal con media 0 y varianza constante.

Distribuciones continuas

- **Gamma**:
  - Adecuada para variables **positivas** como costos, tiempos de espera o duraciones de vida.
  - Posee dos parámetros (α y β, o `shape` y `scale`) que ajustan la asimetría.

Distribuciones continuas

- **Exponencial** (caso particular de la Gamma):
  - Modela “tiempos hasta un suceso” con una tasa constante de ocurrencia; se usa frecuentemente en **confiabilidad** y **teoría de colas**.

Distribuciones discretas

- **Binomial**:
  - Ideal para casos en que tenemos n ensayos con probabilidad p de éxito.
  - Se aplica cuando se desea contar **cuántas veces ocurre un evento** en un número fijo de oportunidades.

Distribuciones de probabilidad

Distribuciones discretas

- **Poisson**:
  - Modela conteos de sucesos en un intervalo (tiempo, espacio) con promedio λ.
  - Frecuente para conteos de clientes, llamadas telefónicas, eventos de falla.

Distribuciones de probabilidad

Por qué es fundamental:

- Las distribuciones forman el **bloque inicial** que conecta la **teoría** (probabilidad) con la **práctica** (modelos).
- Si elegimos una distribución inadecuada para los datos, la inferencia y las predicciones se verán seriamente comprometidas.

Pruebas de hipótesis

Pruebas de hipótesis

Concepto

- Las **pruebas de hipótesis** nos ayudan a tomar decisiones basadas en datos, evaluando si un efecto observado es significativo o producto del azar.

Pruebas de hipótesis

Pasos generales en una prueba de hipótesis

1. **Definir hipótesis:**
   - H_0 **(Hipótesis nula)**: No hay efecto o diferencia.
   - H_1 **(Hipótesis alternativa)**: Hay un efecto o diferencia.
2. **Elegir un nivel de significancia** (α, comúnmente 0.05).
3. **Calcular una estadística de prueba** (Ej: t-student, chi-cuadrado, etc.).
4. **Comparar con un valor crítico** o calcular el **p-valor**.
5. **Tomar una decisión**: Rechazar o no H_0.

Pruebas de hipótesis

Principales pruebas vistas

- **Prueba t**:
  - Se usa para comparar **una media** con un valor teórico o **dos medias** entre sí.
  - Aplicación: Comparar el rendimiento de dos estrategias de marketing.

Pruebas de hipótesis

Principales pruebas vistas

- **Prueba z**:
  - Similar al test t, pero se usa cuando el tamaño muestral es grande ($n > 30$).
  - Aplicación: Evaluar diferencias en ingresos entre dos regiones con grandes muestras.

Pruebas de hipótesis

Principales pruebas vistas

- **Prueba chi-cuadrado**:
  - Evalúa la independencia entre **variables categóricas** en una tabla de contingencia.
  - Aplicación: Analizar si la compra de un producto está relacionada con el género del cliente.

Pruebas de hipótesis

Principales pruebas vistas

- **Prueba de Breusch-Pagan**:
  - Detecta **heterocedasticidad** en la regresión lineal (si la varianza de los errores no es constante).
  - Aplicación: Evaluar si un modelo de predicción de ventas tiene varianza de errores desigual en diferentes niveles de ingresos.

Pruebas de hipótesis

Principales pruebas vistas

- **Pruebas de normalidad (Kolmogorov-Smirnov, Shapiro-Wilk, Jarque-Bera)**:
  - Verifica si los residuos de un modelo de regresión siguen una distribución Normal.
  - Aplicación: Evaluar si la regresión lineal es válida en términos de sus supuestos.

Pruebas de hipótesis

Aplicaciones

- **En marketing**: Evaluar si una nueva estrategia de ventas mejora las conversiones.
- **En salud**: Determinar si un nuevo medicamento mejora la recuperación de pacientes.
- **En calidad**: Comparar defectos en distintos lotes de producción.

¿Qué veremos hoy?

- Distribuciones de probabilidad
- Pruebas de hipótesis
- **Regresión lineal**
- Regresión logística
- Técnicas de selección de variables y modelos

Regresión lineal

Regresión lineal

Ecuación base

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \epsilon,$$

donde ϵ se asume Normal$(0, \sigma^2)$ y Y es continua.

Regresión lineal

Supuestos principales

1. **Linealidad**: el efecto de cada predictor es aditivo y lineal sobre Y.
2. **Independencia**: errores independientes entre sí (importante al recolectar datos).
3. **Normalidad de los errores**: $\epsilon \sim N(0, \sigma^2)$.
4. **Homoscedasticidad**: la varianza de ϵ es constante para todos los niveles de X.

Regresión lineal

Diagnósticos

- Graficar residuos vs predicciones, test de normalidad de residuos, etc.
- Permiten verificar si realmente el modelo lineal es adecuado para los datos.

Regresión lineal

Métricas de evaluación

- R^2 **(Coeficiente de determinación):**
  - Mide qué porcentaje de la variabilidad de Y es explicada por el modelo.
  - $R^2 = 1 - \frac{SSE}{SST}$, donde SSE es la suma de errores al cuadrado y SST la suma total de variaciones.
- **RMSE (Root Mean Squared Error)**
  - Cuantifica el error promedio en las predicciones.
  - $\text{RMSE} = \sqrt{\frac{1}{n}\sum(y_i - \hat{y_i})^2}$.

Regresión lineal

Aplicaciones típicas

- **Finanzas**: estimar precios de acciones con factores macroeconómicos (si la respuesta no varía drásticamente).
- **Negocios**: estimar ventas a partir de presupuesto de marketing (cuando el gasto de marketing y las ventas guardan una relación aproximadamente lineal).

Regresión lineal

- A lo largo del curso aprendimos que la **regresión lineal** es potente, pero limitada si la variable respuesta o sus errores no siguen el comportamiento Normal, o si la respuesta no es continua (por ejemplo, conteos o 0/1).

¿Qué veremos hoy?

- Distribuciones de probabilidad
- Pruebas de hipótesis
- Regresión lineal
- **Regresión logística**
- Técnicas de selección de variables y modelos

Regresión logística

Concepto

- Cuando la respuesta es 0/1 (por ejemplo, “fracaso”/“éxito”), la regresión lineal ya no es apropiada.
- La regresión logística asume que la respuesta es Bernoulli con probabilidad p, y modela $\log\left(\frac{p}{1-p}\right)$ como una combinación lineal de predictores.

Regresión logística

Concepto de Odds y Odds Ratio

- En regresión logística, modelamos la probabilidad de éxito ($P(Y = 1)$) mediante los **odds**:

$$\text{Odds} = \frac{P(Y=1)}{P(Y=0)}$$

- La regresión logística modela el **logaritmo de los odds**:

$$\log\left(\frac{P(Y=1)}{P(Y=0)}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

Regresión logística

Concepto de Odds y Odds Ratio

- **Interpretación de los coeficientes:**
  - e^{β_j} representa el **odds ratio**: cuánto se multiplican los odds cuando X_j aumenta en una unidad.

Regresión logística

Matriz de confusión y tipos de errores

	Pred ($\hat{Y} = 1$)	**Pred** ($\hat{Y} = 0$)
Real $Y = 1$	Verdadero Positivo (VP)	Falso Negativo (FN)
Real $Y = 0$	Falso Positivo (FP)	Verdadero Negativo (VN)

Regresión logística

Tipos de errores

- **Falso Positivo (FP):** El modelo predice que un evento ocurrirá, pero no ocurre (Ej: Predecir fraude cuando no lo es).
- **Falso Negativo (FN):** El modelo no predice un evento, pero ocurre (Ej: No detectar una enfermedad cuando el paciente la tiene).

Regresión logística

Métricas clave

- **Accuracy (Precisión global):**

$$\frac{VP+VN}{VP+VN+FP+FN}$$

- **Precision (Precisión positiva):**

$$\frac{VP}{VP+FP}$$

- **Recall (Sensibilidad o Tasa de Verdaderos Positivos):**

$$\frac{VP}{VP+FN}$$

Regresión logística

Aplicaciones

- Clasificación de correos spam.
- Diagnóstico de enfermedades.
- Predicción de fraudes en tarjetas de crédito.

Regresión logística

- A lo largo del curso aprendimos que la regresión logística permite modelar decisiones binarias y su interpretación se basa en **odds ratios**.

¿Qué veremos hoy?

- Distribuciones de probabilidad
- Pruebas de hipótesis
- Regresión lineal
- Regresión logística
- **Técnicas de selección de variables y modelos**

Técnicas de selección de variables y modelos

Técnicas de selección de variables y modelos

Separación en Train/Test y Overfitting

- **Train/Test Split**:
  - Al entrenar un modelo, dividimos los datos en **conjunto de entrenamiento** y **conjunto de prueba**.
  - El modelo aprende sobre los datos de entrenamiento y se evalúa en los datos de prueba.

Técnicas de selección de variables y modelos

Separación en Train/Test y Overfitting

- **Overfitting** (Sobreajuste):
  - Ocurre cuando el modelo se ajusta demasiado a los datos de entrenamiento y pierde capacidad de generalización.
  - Se puede mitigar usando **validación cruzada**, regularización (Lasso, Ridge) o técnicas de selección de variables como **Stepwise o SFS**.

Técnicas de selección de variables y modelos

AIC y BIC para comparación de modelos

- **AIC (Akaike Information Criterion)**
  $AIC = -2\log L + 2k$ donde L es la verosimilitud y k es el número de parámetros.

- **BIC (Bayesian Information Criterion)**
  $BIC = -2\log L + k\log(n)$

Técnicas de selección de variables y modelos

AIC y BIC para comparación de modelos

- **Interpretación:**
  - Valores más bajos de AIC/BIC indican mejor balance entre ajuste y complejidad.
  - **AIC** prioriza modelos con mejor ajuste, **BIC** penaliza más la complejidad.

Técnicas de selección de variables y modelos

Stepwise Selection (Selección paso a paso)

- **Método automático** que **agrega o elimina** variables basándose en su impacto en el modelo.
- **Dos variantes**:
  - **Forward Selection**: Comienza con ninguna variable y agrega las más significativas.
  - **Backward Elimination**: Comienza con todas las variables y elimina las menos significativas.

Técnicas de selección de variables y modelos

Stepwise Selection (Selección paso a paso)

- **Criterios de eliminación/adición**:
  - p-value de cada coeficiente (test t).
  - AIC o BIC (se busca reducirlos).

Técnicas de selección de variables y modelos

SFS (Sequential Feature Selection)

- Método iterativo que selecciona un subconjunto de variables optimizando una métrica específica.
- Puede ser **hacia adelante (SFS Forward)** o **hacia atrás (SFS Backward)**.
- Diferencias con Stepwise:
  - Stepwise usa pruebas de significancia (p-value).
  - SFS optimiza una métrica (Ej: RMSE, R^2, AIC, etc.).

Técnicas de selección de variables y modelos

Aplicaciones

- Optimizar modelos de regresión para reducir el número de predictores sin perder precisión.
- Evitar overfitting en modelos con muchas variables.

GLM

GLM

Concepto

- Los **Modelos Lineales Generalizados (GLM)** extienden la regresión lineal al permitir modelar **variables respuesta** que no necesariamente siguen una distribución normal.
- Se utilizan cuando la relación entre la variable dependiente y las variables independientes no es lineal en la escala natural de los datos.

Concepto

Los GLM permiten modelar variables respuesta con distribuciones como:

- **Poisson**: Para conteos (Ej: número de clientes que visitan una tienda, fallas en una máquina).
- **Gamma**: Para variables continuas y positivas (Ej: costos de reclamaciones en seguros, tiempos de espera).
- **Binomial**: Para proporciones o tasas de éxito (Ej: porcentaje de conversiones en marketing digital).

GLM

Concepto central

Un GLM está definido por **tres componentes clave**:

1. **La distribución de la variable respuesta**
   - La variable Y proviene de una familia de la **familia exponencial** (Normal, Binomial, Poisson, Gamma, etc.).
   - Esto nos permite modelar **diferentes tipos de variables**, no solo continuas y normales.

GLM

Concepto central

GLM

Concepto central

3. **La función del predictor lineal η**

- Se expresa como: $ = _0 + _1 X_1 + + _k X_k $
- Aunque la relación entre Y y X no es lineal en la escala original, sí lo es en la escala transformada.

GLM

¿Por qué son flexibles?

Comparación con Regresión Lineal

Característica	Regresión Lineal	GLM
Distribución	Normal ($\epsilon \sim N(0, \sigma^2)$)	Cualquier distribución de la familia exponencial
Función de Enlace	Identidad ($\mu = \eta$)	Log, logit, inversa, etc.
Variable Y	Continua	Continua, binaria, conteos, tiempos positivos
Estimación	Mínimos Cuadrados (OLS)	Máxima Verosimilitud (MLE)
Coeficientes	Cambio absoluto en Y por unidad de X	Depende de la función de enlace

GLM

Interpretación de coeficientes según la función de enlace

El impacto de una variable independiente en Y depende de la **función de enlace** elegida:

1. **Enlace Identidad** ($\mu = \eta$) → Regresión Lineal
   - β_j representa el cambio absoluto en Y cuando X_j aumenta en una unidad.

GLM

Interpretación de coeficientes según la función de enlace

2. **Enlace Logit** ($\log \frac{\mu}{1-\mu}$) → Regresión Logística

- e^{β_j} es el **odds ratio**: cuánto se multiplica la probabilidad de éxito cuando X_j aumenta en una unidad.

GLM

Interpretación de coeficientes según la función de enlace

3. **Enlace Log** ($\log \mu$) → Poisson, Gamma

- e^{β_j} indica el **factor multiplicativo** en la media esperada de Y cuando X_j aumenta en una unidad.

Diagnósticos y Evaluación

Dado que los GLM se estiman por **Máxima Verosimilitud**, no podemos usar R^2 como en la regresión lineal. En su lugar, utilizamos:

1. **AIC (Akaike Information Criterion)**

2. **BIC (Bayesian Information Criterion)**

3. **Pseudo-R^2**

   - No es igual al R^2 clásico, pero mide qué tan bien se ajusta el modelo.
   - **Nagelkerke** R^2 es una opción común para modelos GLM.

Diagnósticos y Evaluación

4. Residuos Pearson y Deviance

- Para verificar si el modelo se ajusta bien a los datos.
- Se usan gráficos de residuos vs predicciones para detectar patrones no modelados.

GLM

Aplicaciones

Los GLM son utilizados en una gran variedad de áreas:

Área	Aplicación
Salud	Modelar la probabilidad de una enfermedad (Binomial, Logit)
Finanzas	Modelar pérdidas en siniestros de seguros (Gamma, Log)
Industria	Predecir fallas de máquinas (Poisson, Log)
Marketing	Estimar tasas de conversión en campañas digitales (Binomial, Logit)
Logística	Modelar el número de pedidos por día (Poisson, Log)

Cierre

Cierre

A lo largo del curso hemos aprendido que:

1. **La elección de la distribución** está ligada a la **naturaleza de la variable respuesta** (continua, binaria, conteo, positiva, etc.).
2. **La regresión lineal** es un **caso específico** dentro de un panorama más amplio de modelado estadístico.
3. **La regresión logística** abordó problemas de clasificación binaria, siendo clave en **marketing, salud y finanzas**.
4. **Los GLM** unifican y extienden estas técnicas, permitiendo modelar una gran variedad de fenómenos bajo un mismo **lenguaje estadístico**.